



Escuela
Politécnica
Superior

Predicción del precio horario del mercado eléctrico español



Máster Universitario en Ciencia de Datos

Trabajo Fin de Máster

Autor:
Yassin Ettijani El Barni
Tutor/es:
Alejandro Reina Reina



Universitat d'Alacant
Universidad de Alicante

Septiembre 2026

Índice

Resumen	4
Abstract	5
1 Introducción	6
1.1 Importancia y vigencia del tema	6
1.1.1 La crisis energética y el coste político del precio eléctrico . .	6
1.1.2 La transición renovable y los nuevos regímenes de precio . .	6
1.1.3 El apagón ibérico del 28 de abril de 2025	7
1.2 Motivación	7
1.3 Planteamiento del problema	8
1.4 Alcance del trabajo y de esta memoria	8
1.5 Estructura del documento	9
2 Marco teórico	10
2.1 El mercado eléctrico español	10
2.1.1 Estructura general del sistema eléctrico	10
2.1.2 El Mercado Ibérico de Electricidad y el mercado diario	11
2.1.3 El acoplamiento europeo de mercados	11
2.2 Factores determinantes del precio horario	12
2.2.1 La demanda eléctrica como impulsor principal	12
2.2.2 El mix de generación, la penetración renovable y el orden de mérito	12
2.2.3 Los mercados de commodities energéticas	13
2.2.4 Las variables meteorológicas	16
2.2.5 El calendario	16
2.3 Fuentes de datos públicas	16
2.3.1 ESIOS, Sistema de Información del Operador del Sistema . .	16
2.3.2 AEMET OpenData, datos meteorológicos	17
2.4 Estado del arte en predicción de precios eléctricos	17
2.4.1 Modelos estadísticos clásicos	17
2.4.2 Modelos de aprendizaje automático	18
2.4.3 Modelos de aprendizaje profundo	18
2.4.4 Plataformas y servicios comerciales existentes	18
2.4.5 Aportación y novedad	19
3 Objetivos	21
3.1 Objetivos generales	21
3.2 Objetivos específicos	21
3.3 Planificación y metodología de gestión	22

4	Análisis exploratorio de datos	25
4.1	La serie temporal del precio y sus regímenes	25
4.2	Estacionalidades del precio	28
4.3	Eventos atípicos: precios negativos y picos extremos	30
4.3.1	El mecanismo económico de los precios negativos	30
4.4	Estructura de autocorrelación	32
4.4.1	Lectura de la ACF	32
4.4.2	Lectura de la PACF	33
4.4.3	Descomposición STL	34
4.5	Implicaciones para el modelado	35
5	Metodología	36
5.1	Formulación del problema de aprendizaje	36
5.2	Pipeline de datos	36
5.3	Ingeniería de variables	37
5.3.1	Variables de lag del precio	37
5.3.2	Variables exógenas anticipadas	37
5.3.3	Codificación cíclica	38
5.3.4	Tratamiento de valores ausentes residuales	38
5.4	Esquema de validación temporal	38
5.5	Familias de modelos	38
5.6	Métricas de evaluación	39
5.6.1	Contraste estadístico de Diebold-Mariano	39
5.7	Explicabilidad con valores SHAP	40
6	Desarrollo experimental	41
6.1	Hallazgo y corrección de un problema de calidad de datos	41
6.2	Configuración de los modelos entrenados	43
6.2.1	Baselines naïve	43
6.2.2	SARIMAX	43
6.2.3	XGBoost y LightGBM	44
6.2.4	LSTM	44
6.2.5	Modelo híbrido adaptativo	44
7	Resultados	45
7.1	Introducción y resumen de los modelos evaluados	45
7.2	El resultado central: validación frente a test	47
7.3	Resultados del modelo híbrido adaptativo	48
7.4	LightGBM en detalle: qué aprende bien y dónde falla	50
7.5	Los modelos “convencionales”: dónde y por qué fallan	51
7.6	Contraste de Diebold-Mariano	52
7.7	Predicción con intervalo de confianza sobre un rango de validación	53
7.8	Sobreajuste en la red LSTM	55
7.9	Explicabilidad con SHAP	57
7.9.1	Importancia global de variables: LightGBM	57
7.9.2	Coherencia entre modelos: SHAP comparado	58
7.9.3	Una advertencia necesaria: variables correlacionadas	59
7.9.4	Casos individuales paradigmáticos	60
7.10	Síntesis del capítulo	63
8	Conclusiones	65
8.1	Resumen de la problemática y del recorrido del trabajo	65

8.2 Cumplimiento de los objetivos	66
8.3 Robustez ante cambios de régimen: la aportación central de este trabajo	66
8.4 Sobre las variables que más influyen	67
8.5 Sobre el hallazgo de calidad de datos	67
8.6 Limitaciones y líneas futuras	67
Bibliografía	69
Listado de acrónimos y abreviaturas	71

Resumen

El precio del mercado mayorista de electricidad en España se ha convertido en una variable crítica para la economía del país. Entre 2018 y 2026 esta serie ha atravesado transformaciones estructurales poco habituales para una magnitud económica de primer orden: la crisis energética derivada de la invasión rusa de Ucrania, la excepción ibérica (un tope regulatorio al precio del gas en la generación eléctrica), la aparición sistemática de precios negativos asociados al crecimiento fotovoltaico, y el apagón general del 28 de abril de 2025. Predecir el precio horario del día siguiente no es, por tanto, un ejercicio académico abstracto, sino una necesidad operativa real.

Este Trabajo de Fin de Máster aborda la predicción del precio horario del mercado diario español (*day-ahead forecasting*, horizonte de 24 horas). A partir de las APIs públicas de ESIOS y AEMET se ha construido un conjunto de datos horario real y continuo (enero 2018 a septiembre 2026), sobre el que se ha realizado un análisis exploratorio que caracteriza tres regímenes históricos claramente diferenciados. Sobre ese conjunto de datos se han diseñado, implementado y comparado seis familias de modelos: baselines naïve, SARIMAX con variables exógenas (incluida una serie propia de gas TTF y CO₂), XGBoost, LightGBM, una red LSTM, y un **modelo híbrido adaptativo de elaboración propia** que combina LightGBM con un baseline de persistencia mediante un peso dinámico basado en la volatilidad reciente del mercado. La evaluación emplea tres particiones cronológicas (entrenamiento 2018-2023, validación 2024, test 2025-2026), el contraste de Diebold-Mariano y un análisis de explicabilidad SHAP.

Los resultados muestran que los cuatro modelos estáticos superan con claridad a los baselines en validación, pero pierden esa ventaja en test, que corresponde íntegramente al régimen post-apagón nunca visto en el entrenamiento: ni siquiera LightGBM, el mejor de los cuatro, bate al baseline naïve más simple. El modelo híbrido adaptativo revierte ese resultado, obteniendo el mejor MAE de test de los ocho modelos (5,7 % mejor que el mejor baseline y 21,7 % mejor que LightGBM puro), con significación estadística y robustez frente a sus hiperparámetros. Esta es la conclusión central del trabajo: la pérdida de precisión ante un cambio de régimen no es una limitación inevitable del aprendizaje automático, sino un problema de diseño con solución de ingeniería concreta y evaluable. Adicionalmente, se detectó y corrigió, consultando la documentación oficial de la API, la causa exacta de un problema de calidad de datos en varios indicadores de ESIOS.

Palabras clave: predicción de precios eléctricos, mercado mayorista, OMIE, ESIOS, series temporales, aprendizaje automático, aprendizaje profundo, energías renovables, modelos adaptativos.

Abstract

The price of electricity in the Spanish wholesale market has become a critical economic variable. Between 2018 and 2026 this series has undergone unusual structural changes: the energy crisis triggered by the Russian invasion of Ukraine, the Iberian exception (a regulatory cap on gas prices for power generation), the systematic emergence of negative prices linked to photovoltaic growth, and the general blackout of 28 April 2025. Accurately forecasting the next day's hourly price is therefore a genuine operational need, not an abstract exercise.

This thesis addresses day-ahead hourly forecasting of the Spanish market price. A real, continuous hourly dataset (January 2018 to September 2026) was built from the public APIs of ESIOS and AEMET, and an exploratory analysis identified three clearly differentiated historical regimes. Six model families were designed and compared: naïve baselines, SARIMAX with exogenous regressors (including an original TTF gas and CO2 series), XGBoost, LightGBM, an LSTM network, and an **original adaptive hybrid model** blending LightGBM with a persistence baseline through a dynamic weight driven by recent market volatility. Evaluation uses a three-way temporal split (training 2018-2023, validation 2024, test 2025-2026), the Diebold-Mariano test, and SHAP explainability analysis.

Results show the four static models clearly outperform baselines in validation but lose that edge in test, which falls entirely within the post-blackout regime never seen in training: not even LightGBM, the best of the four, beats the simplest naïve baseline. The proposed hybrid reverses this outcome, achieving the best test MAE of all eight models (5.7% better than the best baseline, 21.7% better than LightGBM alone), with statistical significance and robustness to its hyperparameters. This is the thesis's central conclusion: accuracy loss under regime shift is not an inevitable limitation of machine learning, but a design problem with a concrete, evaluable engineering solution. Additionally, the exact cause of a data quality issue in several ESIOS indicators was identified and corrected by consulting the API's official documentation.

Keywords: electricity price forecasting, wholesale market, OMIE, ESIOS, time series, machine learning, deep learning, renewable energy, adaptive models.

Capítulo 1

Introducción

1.1 Importancia y vigencia del tema

El precio de la electricidad ha pasado, en menos de una década, de ser una magnitud relativamente estable y discutida solo en círculos especializados a convertirse en un asunto de primera línea política, económica y social en España. Antes de plantear el problema técnico concreto que aborda este trabajo conviene situar, con datos y referencias verificables, por qué esta cuestión es tan relevante en este momento.

1.1.1 La crisis energética y el coste político del precio eléctrico

Durante los años 2021 y 2022, el precio medio diario del mercado mayorista español superó en varias ocasiones los 400 €/MWh, con picos puntuales muy por encima de los 300 €/MWh [6, 7], frente a una media histórica previa que rondaba los 50 €/MWh. El efecto sobre el bono social, sobre el Precio Voluntario para el Pequeño Consumidor (PVPC)¹ y sobre la factura de los hogares fue inmediato, y dio lugar a la aprobación, el 13 de mayo de 2022, del Real Decreto-ley 10/2022 [3], conocido coloquialmente como tope ibérico al gas o excepción ibérica: un mecanismo regulatorio extraordinario, autorizado por la Comisión Europea, que limitaba el precio del gas natural utilizado para generación eléctrica. El mecanismo entró en vigor el 14 de junio de 2022 y estuvo vigente, con sucesivas prórrogas, hasta finales de 2023. La intervención modificó de raíz la dinámica del precio durante ese periodo, tal y como se constata en el análisis exploratorio del capítulo 4 de esta memoria.

1.1.2 La transición renovable y los nuevos regímenes de precio

España ha sido uno de los protagonistas europeos de la transición energética: en 2025 la generación renovable superó el 56 % de la generación anual peninsular, y el país lidera, junto con Alemania, la potencia fotovoltaica instalada de la Unión Europea.² El Plan Nacional Integrado de Energía y Clima (PNIEC) [4] fija como

¹El detalle de la tarifa PVPC y su fórmula de cálculo horaria puede consultarse en la Comisión Nacional de los Mercados y la Competencia: <https://www.cnmc.es/ambitos-de-actuacion/energia/mercado-electrico>

²Los datos mensuales de cobertura de la demanda por tecnología, actualizados, están disponibles en el visor público de Red Eléctrica de España: <https://www.ree.es/es/datos/generacion/estructura->

objetivo alcanzar 76 GW de potencia solar y 62 GW de potencia eólica instalada en 2030. Este crecimiento produce fenómenos de mercado que hace una década eran anecdóticos y que hoy son rutinarios: precios negativos en horas de alta producción solar y picos vespertinos extremos en invierno cuando la solar deja de aportar. El capítulo 4 cuantifica ambos fenómenos con datos reales del periodo 2018-2026.

1.1.3 El apagón ibérico del 28 de abril de 2025

El 28 de abril de 2025, a las 12:33 hora local, la península ibérica sufrió un colapso eléctrico generalizado. España, Portugal, Andorra y zonas del sur de Francia quedaron sin suministro durante horas. El informe final del panel de expertos de la Red Europea de Gestores de Redes de Transporte de Electricidad (ENTSO-E) [5], publicado en marzo de 2026 tras casi un año de investigación con un panel de 49 expertos, concluye que el apagón fue el resultado de una combinación de factores técnicos y regulatorios (deficiencias en el control de tensión y de potencia reactiva, prácticas de regulación de tensión heterogéneas entre instalaciones, y desconexiones en cascada de generación en España), y no atribuye la causa principal a la elevada penetración renovable del sistema, aunque sí señala el papel de determinadas instalaciones fotovoltaicas cuyas protecciones de sobretensión se desconectaron antes de lo previsto en su punto de conexión. Las consecuencias económicas son visibles en la serie del precio: durante los meses posteriores al apagón, Red Eléctrica de España adoptó restricciones operativas que mantuvieron reservas de potencia anormalmente altas, lo que elevó de forma sostenida los precios marginales en las horas críticas, tal y como se documenta en el capítulo 4. El periodo post-apagón se ha convertido, así, en un caso paradigmático de cambio de régimen abrupto en una serie temporal, y constituye el argumento metodológico central de este trabajo: la partición de test empleada para evaluar los modelos (capítulo 5) cae íntegramente dentro de este nuevo régimen.

1.2 Motivación

Para el sector profesional (comercializadoras eléctricas, grandes consumidores industriales, operadores de almacenamiento por baterías, agregadores de demanda y traders energéticos), la predicción del precio horario del día siguiente es una variable estratégica de decisión. La cantidad de energía que una empresa decide comprar o vender en cada hora del día siguiente, los contratos de cobertura que firma, el momento en que carga o descarga una batería, o la potencia que ofrece como flexibilidad al sistema, dependen directamente de la previsión de precio que maneja para esas próximas horas. Según la revisión de Lago et al. [2], una mejora de pocos euros por megavatio-hora en el error medio de predicción puede traducirse en ahorros operativos significativos para una comercializadora de tamaño medio. En el ámbito académico, este problema se conoce como *electricity price forecasting* (EPF) y constituye una línea de investigación activa desde finales de los años noventa, con publicaciones regulares en revistas como *International Journal of Forecasting*, *Applied Energy* o *Energy Economics* [1, 2].

generacion

España presenta, además, una particularidad que la convierte en un caso de estudio especialmente interesante: la combinación de una penetración renovable muy alta con un mercado acoplado a escala europea produce fenómenos que hace una década eran prácticamente inexistentes y que hoy son rutinarios, entre ellos los precios negativos en horas de alta producción solar, los picos vespertinos extremos en invierno, y los desacoplamientos respecto al mercado francés que provocan diferenciales de precio notables entre la península ibérica y el resto de la Europa continental (sección 2.1.3). Predecir bien este mercado exige, por tanto, modelos que sepan capturar tanto la estacionalidad clásica de la demanda como las nuevas dinámicas inducidas por las renovables variables, y es precisamente ese reto técnico, unido a un interés profesional por incorporarme a perfiles de Data Scientist centrados en mercados de energía, lo que motiva la elección de este tema para el Trabajo de Fin de Máster.

1.3 Planteamiento del problema

El problema que se aborda en este Trabajo de Fin de Máster se formula del siguiente modo. Dada la serie horaria histórica del precio del mercado SPOT diario español (en adelante, precio horario) y un conjunto de variables explicativas conocidas con anticipación de al menos 24 horas (demanda eléctrica prevista, generación renovable reciente, variables de calendario, variables meteorológicas), se quiere construir un modelo f que estime, para cada hora h del día $D + 1$, el precio $\hat{p}_{D+1,h}$ a partir de la información disponible en el día D antes del cierre de la subasta del mercado diario (12:00 del día D):

$$\hat{p}_{D+1,h} = f\left(x_{D+1,h}^{ex}, p_{D,\cdot}, p_{D-1,\cdot}, \dots\right), \quad h \in \{0, 1, \dots, 23\} \quad (1.1)$$

donde $x_{D+1,h}^{ex}$ representa el vector de variables explicativas exógenas asociadas a la hora h del día $D + 1$ y conocidas con antelación suficiente, y $p_{D,\cdot}$ denota los precios horarios observados en días anteriores.

La serie de precios de la electricidad en España ha experimentado cambios estructurales profundos entre 2018 y 2026, tal y como se ha adelantado en la sección 1.1 y se cuantifica en el capítulo 4. En este contexto, el interés no reside únicamente en encontrar un modelo con un buen comportamiento agregado sobre la totalidad del histórico, sino en evaluar su capacidad para adaptarse a los distintos regímenes presentes en la serie. Por tanto, el objetivo va más allá de minimizar una métrica global: se busca también caracterizar cómo se comportan distintas familias de modelos ante esos cambios de régimen, identificar qué variables resultan más informativas en cada momento del año y del día, y proponer una arquitectura predictiva robusta ante futuros eventos extremos similares a los ya observados. Como se verá en el capítulo 7, esta última cuestión (la robustez ante cambios de régimen) termina siendo, de hecho, el resultado más importante de todo el trabajo.

1.4 Alcance del trabajo y de esta memoria

El alcance del TFM abarca cuatro grandes bloques de trabajo: (i) la construcción reproducible de un conjunto de datos horario completo del mercado español

desde 2018, integrando datos de ESIOS y AEMET; (ii) un análisis exploratorio riguroso que caracterice los regímenes históricos del mercado y justifique las decisiones de modelado; (iii) el entrenamiento, validación y comparación de seis familias de modelos predictivos (baselines, un modelo estadístico, dos modelos de gradient boosting, una red neuronal recurrente, y un modelo híbrido adaptativo de elaboración propia); y (iv) el análisis de los resultados, con explicabilidad mediante SHAP y conclusiones sobre qué modelo predice mejor y por qué.

Esta memoria recoge el trabajo completo, de principio a fin: comprende la introducción, el marco teórico, la formulación de objetivos, el análisis exploratorio de datos reales, la metodología, el desarrollo experimental, los resultados obtenidos y las conclusiones finales. El código completo, ejecutado y con sus salidas reales (tablas y figuras), se entrega como material complementario en forma de dos notebooks reproducibles: uno para la adquisición de datos y otro para el análisis exploratorio, el modelado y la evaluación.

1.5 Estructura del documento

El resto de la memoria se organiza en los siguientes capítulos, siguiendo lo dispuesto en la norma UNE 50136:1997 y en las directrices de estilo de la Escuela Politécnica Superior de la Universidad de Alicante.

Capítulo 1. Introducción. Justifica la elección del tema, sitúa el problema en su contexto técnico, regulatorio y social, y formula el problema de predicción.

Capítulo 2. Marco teórico. Describe el funcionamiento del mercado mayorista español, los factores que determinan la formación del precio horario, las fuentes de datos públicas disponibles y el estado del arte en predicción de precios eléctricos.

Capítulo 3. Objetivos. Formaliza los objetivos generales y específicos del trabajo, y presenta la planificación temporal y la metodología de gestión del proyecto.

Capítulo 4. Análisis exploratorio de datos. Caracteriza, con datos reales, los tres regímenes históricos del precio, sus estacionalidades, sus eventos atípicos y su estructura de autocorrelación.

Capítulo 5. Metodología. Define el problema de aprendizaje, el pipeline de datos, la ingeniería de variables, el esquema de validación, las familias de modelos y las métricas de evaluación.

Capítulo 6. Desarrollo experimental. Detalla el hallazgo y la corrección de un problema de calidad de datos, y la configuración concreta con la que se entrenó cada modelo.

Capítulo 7. Resultados. Presenta y analiza en profundidad los resultados obtenidos, compara los modelos con significación estadística, y aplica SHAP para explicar y contrastar el comportamiento de los mejores modelos.

Capítulo 8. Conclusiones. Resume las aportaciones del trabajo, evalúa el cumplimiento de los objetivos planteados y propone líneas de trabajo futuro.

Nota: el código fuente completo de este trabajo, organizado, comentado y ejecutable, está publicado en el repositorio público de GitHub
<https://github.com/elbarni53-eng/TFM--Prediccion-Precio-De-La-Luz>

Capítulo 2

Marco teórico

Este capítulo se organiza en cuatro bloques. El primero (sección 2.1) describe la arquitectura del mercado mayorista de electricidad en España y el mecanismo de casación del mercado diario gestionado por OMIE. El segundo (sección 2.2) examina los factores que determinan la formación del precio horario. El tercero (sección 2.3) describe las fuentes públicas de datos utilizadas. El último (sección 2.4) revisa el estado del arte académico en predicción de precios eléctricos.

2.1 El mercado eléctrico español

2.1.1 Estructura general del sistema eléctrico

El sistema eléctrico español es un sistema regulado, parcialmente liberalizado y profundamente integrado en el mercado eléctrico europeo. Intervienen, a grandes rasgos, cuatro tipos de agentes con roles diferenciados: los productores de electricidad inyectan energía al sistema desde sus instalaciones de generación; los comercializadores compran energía en los mercados mayoristas y la revenden a los consumidores finales; los consumidores son el sumidero final del flujo energético; y, por encima de todos ellos, dos operadores institucionales con funciones distintas pero complementarias.

El operador del sistema es Red Eléctrica de España (REE) [6], filial del grupo Redeia Corporación, S.A., que opera la red de transporte de alta tensión y garantiza el equilibrio instantáneo entre generación y demanda en tiempo real. El operador del mercado es el Operador del Mercado Ibérico de Energía, polo español (OMIE) [7],¹ que celebra las subastas del mercado diario y los mercados intradiarios y publica los precios resultantes para cada hora. Esta separación entre operador del sistema y operador del mercado es la que hace posible que existan datos públicos de precio (los publica OMIE, y también ESIOS como espejo) y datos públicos de operación física (los publica REE a través de ESIOS).

¹Los resultados horarios de cada subasta del mercado diario, incluidas las curvas de oferta y demanda agregadas, pueden consultarse públicamente en <https://www.omie.es/es/market-results/daily/daily-market/daily-hourly-price>

2.1.2 El Mercado Ibérico de Electricidad y el mercado diario

España y Portugal forman, desde 2007, el Mercado Ibérico de Electricidad (MIBEL), un mercado mayorista común gestionado por OMIE en su polo español y por OMIP en su polo portugués. El componente más importante del MIBEL, y la fuente del indicador objetivo de este trabajo, es el mercado diario: una subasta marginalista uniforme que se celebra a las 12:00 del día D y en la que se determinan los precios horarios para las 24 horas del día $D + 1$. Su funcionamiento, simplificado, es el siguiente:

1. Cada productor presenta, para cada una de las 24 horas, ofertas de venta de energía indicando la cantidad ofertada y el precio mínimo al que está dispuesto a vender (curva de oferta).
2. Cada comercializador y consumidor cualificado presenta, en paralelo, ofertas de compra con la cantidad demandada y el precio máximo al que está dispuesto a comprar (curva de demanda).
3. Para cada hora, OMIE ordena las ofertas de venta de menor a mayor precio y las ofertas de compra de mayor a menor precio. La intersección de ambas curvas determina la cantidad casada y el precio marginal (el precio único al que se compran y venden todas las unidades casadas en esa hora).
4. Todos los productores cuyas ofertas estén por debajo del precio marginal cobran ese precio, y todos los compradores cuyas ofertas estén por encima pagan ese mismo precio: es el llamado precio marginalista uniforme, o *pay-as-clear*.

Esta regla tiene una consecuencia fundamental para el modelado, que se retoma en la sección 2.2: el precio en cada hora viene determinado por la tecnología más cara que es necesario despachar para cubrir la demanda. Si la demanda se cubre solo con renovables, el precio marginal será muy bajo, incluso cero o negativo; si hay que recurrir a un ciclo combinado de gas, el precio marginal lo fijará el coste variable del gas más el coste del derecho de emisión de CO₂.

2.1.3 El acoplamiento europeo de mercados

El mercado diario español no es un mercado aislado. Desde la implantación progresiva del *Single Day-Ahead Coupling* (SDAC) europeo, los precios diarios de los distintos mercados nacionales se determinan de forma simultánea mediante un algoritmo único, EUPHEMIA, que tiene en cuenta las capacidades disponibles de interconexión entre países. Una descripción pública detallada del algoritmo está disponible en el documento *EUPHEMIA Public Description*, mantenido conjuntamente por los operadores de mercado europeos [18]. La consecuencia operativa es que, cuando la interconexión Francia-España tiene capacidad disponible, los precios ibéricos se acoplan al precio francés; cuando la interconexión se satura, los precios ibéricos se desacoplan y pueden situarse notablemente por debajo o por encima del resto de la Europa continental. Este fenómeno, conocido como *market splitting*, es la razón por la que el indicador 600 de ESIOS, utilizado en este trabajo como variable objetivo, devuelve valores separados para España, Portugal y Francia.

2.2 Factores determinantes del precio horario

El precio marginal del mercado lo fija siempre la tecnología más cara que entra en el despacho para cubrir la demanda de esa hora, tal y como se ha descrito en la sección anterior. El orden de mérito convencional, ordenado por coste marginal de menor a mayor, es aproximadamente el siguiente: renovables (eólica, fotovoltaica) e hidráulica de embalse, después nuclear, después ciclo combinado de gas, y por último tecnologías de respaldo como la cogeneración o el bombeo turbinando. En la práctica, esto significa que cuando la producción renovable e hidráulica basta para cubrir toda la demanda de una hora, el precio de esa hora lo determina la última unidad renovable necesaria (con un coste marginal casi nulo), mientras que en cuanto es necesario recurrir a un ciclo combinado de gas para cubrir el resto de la demanda, es ese ciclo combinado (con un coste marginal mucho más alto, dominado por el precio del gas) el que fija el precio de toda la hora, no solo el de la energía que él mismo aporta.

2.2.1 La demanda eléctrica como impulsor principal

La demanda eléctrica nacional es el primer determinante del precio: a mayor demanda, más generación necesaria, más probable es que las tecnologías marginales entren en el mix, y mayor el precio resultante. La demanda presenta una estacionalidad marcada en tres escalas temporales (horaria, semanal y anual), que se cuantifica con datos reales en la sección 4.2. REE publica diariamente, antes del cierre del mercado, su previsión de demanda para el día $D + 1$ (indicador 460 de ESIOS), un indicador especialmente valioso como variable explicativa porque está disponible antes del momento en que el modelo necesita hacer la predicción.

2.2.2 El mix de generación, la penetración renovable y el orden de mérito

Para entender por qué el precio de una hora puede pasar de 40 €/MWh a 300 €/MWh de un día para otro, hace falta detenerse en el mecanismo de casación descrito en la sección 2.1: en una subasta marginalista uniforme, **el precio de toda la energía casada en una hora lo fija el coste variable de la última central que es necesario despachar para cubrir la demanda de esa hora, no el coste medio del mix, ni el coste de la tecnología más barata.** A esta ordenación de las centrales, de menor a mayor coste variable, se la conoce como orden de mérito, y es la pieza central para entender la formación del precio en cualquier mercado marginalista como el español.

El orden de mérito convencional, de menor a mayor coste variable, es aproximadamente el siguiente: renovables (eólica, fotovoltaica) e hidráulica de embalse en primer lugar, por tener un coste variable prácticamente nulo (no consumen combustible); a continuación la nuclear, con un coste variable bajo pero no nulo; después el ciclo combinado de gas, cuyo coste variable depende directamente del precio del gas natural y del CO₂ (sección 2.2.3); y por último las tecnologías de respaldo (cogeneración, fuelóleo, importaciones en horas de escasez), con los costes variables más altos del sistema. La figura 2.1 ilustra este mecanismo de forma esquemática.




Figura 2.1: Esquema ilustrativo (no derivado de datos reales) de la formación del precio marginal por orden de mérito: la demanda de la hora (línea discontinua) se cubre acumulando tecnologías de menor a mayor coste variable, y el precio de toda la energía casada lo fija el coste de la última tecnología necesaria.

En el ejemplo de la figura, la demanda de la hora (33 GW) se cubre con renovables, nuclear y una parte del parque de ciclo combinado; como el ciclo combinado es la última tecnología necesaria, su coste variable (unos 78 €/MWh en el ejemplo) se convierte en el precio de toda la energía de esa hora, incluida la que producen las renovables y la nuclear a un coste mucho menor. Esta es la razón por la que un simple cambio en la cantidad de renovables disponibles puede desplazar el precio de la hora de forma muy notable sin que cambie ni un céntimo el coste de producir con gas: si hay más renovable disponible, la curva de oferta barata se alarga hacia la derecha, la intersección con la demanda se produce antes, y dejan de ser necesarias las centrales más caras.

Esto explica las dos observaciones empíricas más llamativas del mercado español reciente, ambas cuantificadas con datos reales en el capítulo 4: en primavera, cuando coinciden alta producción solar diurna, temperaturas suaves y embalses llenos, la curva de renovables por sí sola puede llegar a cubrir toda la demanda de las horas centrales del día, dejando fuera del despacho a cualquier central térmica y empujando el precio hacia cero o por debajo (sección 4.3.1); y en invierno, tras el ocaso, la fotovoltaica deja de producir mientras la demanda alcanza su pico vespertino, de modo que si además hay poco viento, el ciclo combinado o incluso tecnologías de respaldo todavía más caras se convierten en la tecnología marginal, disparando el precio de toda la hora.

2.2.3 Los mercados de commodities energéticas

Cuando el ciclo combinado de gas es la tecnología marginal (sección 2.2.2), lo cual sucede en una proporción muy alta de las horas anuales en España, el precio de

toda la hora queda determinado, en esencia, por el coste variable de esa central de gas. Ese coste variable tiene dos componentes que se negocian en mercados de materias primas (*commodities*) completamente ajenos al mercado eléctrico, pero que terminan siendo, indirectamente, el factor explicativo más importante del precio eléctrico en un número relevante de horas: el precio del gas natural y el precio del derecho de emisión de CO₂.

El gas natural (TTF). El precio del gas natural que consumen los ciclos combinados españoles se referencia habitualmente al *Title Transfer Facility* (TTF) neerlandés, el hub de gas de referencia en Europa continental y el precio que cotiza a diario en los mercados de futuros y de contado. La evolución del TTF desde el verano de 2021 (multiplicándose varias veces sobre su nivel previo hasta alcanzar un máximo histórico en torno a 339 €/MWh en marzo de 2022) es la explicación técnica más directa de la crisis energética descrita en la sección 1.1: un gas seis u ocho veces más caro que en 2020 se traduce, a través del mecanismo de orden de mérito, en un coste de generación con ciclo combinado varias veces superior, y ese coste se convierte en el precio de toda la hora en cuanto el gas es la tecnología marginal.

El derecho de emisión de CO₂ (EUA). El segundo componente del coste variable del ciclo combinado es el derecho de emisión de CO₂, negociado en el *Emissions Trading System* (ETS) europeo bajo el código EUA (*EU Allowance*).² Para producir un megavatio-hora eléctrico quemando gas natural, una central de ciclo combinado necesita emitir, y por tanto disponer de derechos para, aproximadamente 0,35 a 0,40 toneladas de CO₂ (el valor exacto depende de la eficiencia de la turbina), de modo que cada euro adicional en el precio de la tonelada de CO₂ se traduce en unos 0,35 a 0,40 €/MWh adicionales en el coste marginal de generar con gas. El precio del EUA ha pasado de cotizar en torno a 25 €/tonelada en 2020 a mantenerse en un rango sostenido de 70 a 90 €/tonelada en 2024-2025.

El coste marginal de generación con ciclo combinado puede aproximarse, de forma simplificada, mediante la siguiente expresión, ampliamente utilizada en la literatura de *electricity price forecasting* [2]:

$$c_{gas}(t) \approx \frac{P_{TTF}(t)}{\eta} + \varepsilon \cdot P_{EUA}(t) \quad (2.1)$$

donde $P_{TTF}(t)$ es el precio del gas TTF en el momento t (€/MWh térmico), η es la eficiencia térmica de la central (típicamente entre 0,50 y 0,58 para un ciclo combinado moderno), y ε es el factor de emisión del gas natural (en torno a 0,37 tCO₂/MWh).

Dado que la ecuación 2.1 señala a $P_{TTF}(t)$ y $P_{EUA}(t)$ como determinantes directos del precio en una fracción muy alta de las horas del histórico, este TFM incorpora ambas series como variables explicativas de pleno derecho, en lugar de limitarse a mencionarlas cualitativamente. No se dispuso de acceso de red a un proveedor de datos financieros de mercado (yfinance, ICE Endex, EEX) desde el entorno de cómputo utilizado durante el desarrollo, así que se ha construido

²El precio diario del EUA en el mercado secundario puede consultarse en el European Energy Exchange: <https://www.eex.com/en/market-data/environmental-markets/eua-primary-auction-spot-download>

una serie diaria completa por interpolación monótona (PCHIP) entre puntos de referencia públicos y verificables: cierres mensuales o de eventos puntuales bien documentados de ICE Endex / Trading Economics para el TTF [8] y de EEX / Ember Carbon Price Tracker para el EUA [9], cada uno con su fuente (tabla 2.1).

Fecha de ancla	TTF (€/MWh)	EUA (€/t)	Contexto
2018-01 - 2020-06	6-21	8-25	Nivel pre-crisis, estable
2021-06 - 2021-12	27-137	52-76	Escalada de la crisis energética
2022-03-07	227	58	Semana de la invasión de Ucrania
2022-08-26	339	79	Máximo histórico (corte de Nord Stream)
2023	30-58	79-97	Normalización parcial del gas, EUA sostenido
2024-2025	31-46	55-80	Nivel post-crisis
2026-07	32	84	Último valor de anclaje verificado

Tabla 2.1. Puntos de anclaje (fecha, valor documentado) usados para construir la serie diaria de gas TTF y derecho de emisión EUA por interpolación PCHIP.




Figura 2.2: Serie diaria de gas TTF y derecho de emisión EUA, construida por interpolación PCHIP entre los puntos de anclaje de la tabla 2.1 (2018-2026).

Esta serie no sustituye a una descarga de mercado real minuto a minuto, pero sí captura correctamente la dinámica de baja frecuencia (semanal y mensual) que es, precisamente, la que explica los grandes movimientos del precio eléctrico visibles en la figura 2.2: la estabilidad de 2018-2020, la escalada de 2021, el máximo de marzo y agosto de 2022, y la normalización progresiva desde 2023.

La serie, replicada a granularidad horaria y desplazada 24 horas, se incorpora como variable explicativa (`gas_ttf_lag24`, `co2_eua_lag24`) en el capítulo 5, y su contribución real a las predicciones se cuantifica mediante SHAP en el capítulo 7.

2.2.4 Las variables meteorológicas

La meteorología actúa sobre el precio por dos canales: sobre la demanda, a través de la temperatura y la necesidad de calefacción o climatización; y sobre la oferta renovable, a través de la irradiancia solar y la velocidad del viento. España es un territorio extenso y la dispersión geográfica de la generación renovable implica que una temperatura única para el conjunto del país sería una simplificación considerable; en este TFM se ha optado por una agregación mediante la media simple de seis estaciones de AEMET distribuidas por las principales zonas climáticas del país (Madrid, Sevilla, Zaragoza, Valencia, A Coruña y Córdoba), dejando como mejora futura una ponderación por la potencia renovable instalada en cada provincia, una práctica habitual en la literatura de *electricity price forecasting* [2].

2.2.5 El calendario

El calendario de festivos nacionales y la propia estructura semanal son factores explicativos clave por su impacto directo sobre la demanda: los festivos rompen el patrón habitual de demanda laborable y, en general, son días con precios más bajos de lo que el modelo predeciría si solo conociera el día de la semana. En este trabajo se ha optado por trabajar exclusivamente con el calendario de festivos nacionales de España, dejando fuera los festivos autonómicos y locales. Esta decisión se justifica por dos motivos: primero, porque el efecto sobre la demanda agregada nacional de un festivo local o autonómico concreto es, salvo excepciones, mucho menor que el de un festivo nacional; y segundo, por simplicidad de implementación, ya que el catálogo de festivos autonómicos y locales exigiría mantener una tabla de correspondencia entre estaciones meteorológicas, comunidades autónomas y provincias que excede el alcance de esta iteración. El catálogo de festivos se obtiene mediante la librería de código abierto `holidays` para Python [10], que mantiene actualizado un calendario de festividades por país, y que es la que efectivamente se utiliza en el código del capítulo 5: no se trata, por tanto, de un calendario introducido manualmente.

2.3 Fuentes de datos públicas

2.3.1 ESIOS, Sistema de Información del Operador del Sistema

ESIOS es la plataforma pública de Red Eléctrica de España a través de la cual el operador del sistema publica toda la información operativa del sistema eléctrico nacional. La plataforma ofrece una API REST, documentada públicamente [11],³ con cientos de indicadores (series temporales) que cubren prácticamente todos los aspectos relevantes del sistema: precios de los distintos mercados, demanda real y prevista, generación medida por tecnología, intercambios internacionales,

³El explorador interactivo de indicadores, con más de 1500 series disponibles y su descripción metodológica, está en <https://www.esios.ree.es/es/analisis>

servicios de ajuste, casaciones, etcétera. El acceso a la API es gratuito previa solicitud de un token personal a través de correo electrónico. En la tabla 2.2 se resumen los indicadores de ESIOS utilizados en este TFM.

ID	Nombre del indicador	Papel en el modelo
600	Precio mercado SPOT diario	Variable objetivo
1293	Demanda real	Variable explicativa
460	Demanda prevista	Variable explicativa anticipada
541	Generación eólica medida	Variable explicativa
10034	Generación solar fotovoltaica medida	Variable explicativa
549	Generación nuclear medida	Variable explicativa
544	Generación ciclo combinado medida	Descartada (sección 6.1)

Tabla 2.2. Indicadores de ESIOS utilizados como variable objetivo y variables explicativas en el TFM.

La API admite consultas por rango temporal y granularidad. En este trabajo se descarga, para cada indicador, el rango completo desde el 1 de enero de 2018 hasta la fecha actual con granularidad horaria.

2.3.2 AEMET OpenData, datos meteorológicos

La Agencia Estatal de Meteorología (AEMET) publica, a través de su plataforma AEMET OpenData, una API REST documentada públicamente [12] que permite acceder a observaciones de su red de estaciones meteorológicas y a las predicciones operativas del modelo de pronóstico de la propia agencia.⁴ Como ESIOS, el acceso requiere un token gratuito previa solicitud. Las variables meteorológicas utilizadas en este trabajo (temperatura media, mínima y máxima diaria, velocidad media del viento y precipitación acumulada) se descargan con granularidad diaria de seis estaciones climatológicas y se replican a las 24 horas correspondientes al construir el conjunto de datos horario.

2.4 Estado del arte en predicción de precios eléctricos

La predicción de precios eléctricos (*electricity price forecasting*, EPF) es una línea de investigación consolidada que comenzó a desarrollarse a finales de los años noventa, en paralelo a la liberalización de los mercados eléctricos europeos. Las revisiones bibliográficas de referencia, en particular el trabajo seminal de Weron [1] y la revisión más reciente de Lago et al. [2], organizan la literatura en tres grandes familias de modelos.

2.4.1 Modelos estadísticos clásicos

La primera generación de modelos EPF se construyó sobre el aparato clásico de series temporales: modelos autorregresivos (AR, ARIMA, SARIMA) y sus extensiones con variables exógenas (ARX, ARIMAX, SARIMAX). Su ventaja es la interpretabilidad y la disponibilidad de un aparato inferencial bien fundamentado;

⁴El portal de acceso a la documentación completa de la API, incluida la guía de autenticación por token, está en <https://opendata.aemet.es/centrodedescargas/inicio>

su limitación principal es la incapacidad para capturar relaciones no lineales y la fuerte dependencia de hipótesis distribucionales que la serie de precio eléctrico viola sistemáticamente (no estacionariedad, leptocurtosis, presencia de picos extremos). A pesar de esas limitaciones, los modelos SARIMAX con variables exógenas siguen siendo un benchmark mínimo obligado en la literatura reciente, y por ello se incluyen en este TFM en la fase comparativa.

2.4.2 Modelos de aprendizaje automático

A partir aproximadamente del año 2010, la literatura EPF ha incorporado de forma masiva técnicas de aprendizaje automático, en particular métodos basados en árboles como Random Forest y, sobre todo, Gradient Boosting en sus implementaciones modernas: XGBoost [13] y LightGBM [14]. La conclusión recurrente en la literatura comparativa, confirmada también en los resultados de este TFM (capítulo 7), es que un gradient boosting con una ingeniería de variables cuidadosa es el modelo de referencia en términos de relación coste-precisión.

2.4.3 Modelos de aprendizaje profundo

La última generación de modelos EPF utiliza arquitecturas de aprendizaje profundo pensadas específicamente para series temporales, en particular las redes recurrentes con celdas *Long Short-Term Memory* (LSTM) [15] y, más recientemente, arquitecturas basadas en atención como el Temporal Fusion Transformer [16]. Estos modelos tienen mayor capacidad de representación, pero también mayor número de hiperparámetros y mayor coste computacional; la evidencia empírica reciente sugiere que solo aportan mejoras sustanciales sobre el gradient boosting cuando se dispone de grandes volúmenes de datos y de buenas variables exógenas conocidas con antelación, una hipótesis que este TFM contrasta directamente en el capítulo 7.

2.4.4 Plataformas y servicios comerciales existentes

Además de la literatura académica, existen ya en el mercado plataformas comerciales que ofrecen predicciones del precio horario español a operadores del sector: servicios de consultoras energéticas y brokers (por ejemplo, AleaSoft, ICIS o Montel) publican previsiones de precio como parte de sus suscripciones profesionales.⁵ Estas plataformas comparten una limitación relevante para el propósito de este TFM: sus modelos son propietarios y no publican qué variables influyen más en cada predicción, lo que impide a sus clientes entender por qué el precio va a subir o bajar y limita la confianza y la toma de decisiones basada en esa información. Esta limitación es, precisamente, la que motiva la aportación diferencial de este trabajo: un análisis de explicabilidad mediante valores SHAP (capítulo 7) que permite comprender qué variables impulsan cada predicción concreta, algo que ninguna de estas plataformas comerciales ofrece hoy de forma abierta.

⁵Un resumen público, no técnico, de este tipo de servicios de previsión de mercado puede consultarse en el portal de análisis de mercado de AleaSoft: <https://aleasoft.com/es/>

2.4.5 Aportación y novedad

El análisis exploratorio del capítulo 4 y la revisión de la literatura de las secciones anteriores convergen en un mismo diagnóstico: los modelos de aprendizaje automático más precisos en promedio son, precisamente, los que peor se comportan cuando el mercado cambia de régimen de forma abrupta, porque su precisión depende de que el futuro se parezca estadísticamente al pasado con el que se entrenaron. Ese diagnóstico, por sí solo, ya es una observación de valor, pero un diagnóstico no es una solución. La aportación central de este TFM es precisamente eso, una solución concreta y evaluable: un mecanismo de arbitraje adaptativo, entrenable con la misma información que ya usa cualquiera de los modelos de este trabajo, que decide en tiempo real cuánto confiar en un modelo sofisticado y cuánto en un baseline robusto, en función de si el mercado se está comportando como en el pasado o no.

La idea, formalizada y evaluada por completo en las secciones 6.2.5 y 7.1.1, es la siguiente. Se define un indicador de volatilidad reciente $\sigma(t)$, la desviación típica móvil del precio en los últimos 7 días, calculado exclusivamente con información ya disponible en el momento de la predicción, y se compara con el nivel de volatilidad que el modelo ya conocía por haberlo visto durante el entrenamiento. La predicción final combina un modelo de gradient boosting y un baseline de persistencia mediante un peso $\lambda(t)$ que depende de esa comparación:

$$\lambda(t) = \frac{1}{1 + (\sigma(t)/\sigma_{ref})^k}, \quad \hat{y}(t) = \lambda(t) \cdot \hat{y}_{ML}(t) + (1 - \lambda(t)) \cdot \hat{y}_{naive}(t) \quad (2.2)$$

Cuando el mercado se comporta con normalidad, $\lambda(t) \rightarrow 1$ y se aprovecha toda la precisión del modelo de árboles; cuando la volatilidad reciente excede claramente lo observado durante el entrenamiento, $\lambda(t) \rightarrow 0$ y el sistema recae, de forma automática y sin intervención humana, en un baseline que no puede extrapolar mal porque no extrapola nada. Ningún parámetro de esta regla se ajusta mirando el resultado sobre los datos de evaluación: σ_{ref} y k se fijan únicamente a partir de la distribución de volatilidad vista en entrenamiento, por diseño, antes de observar cómo se comporta el mercado después.

El resultado, adelantado aquí y desarrollado con todo detalle en el capítulo 7, es contundente: sobre el conjunto de test (que cubre el régimen posterior al apagón ibérico, nunca visto durante el entrenamiento), este mecanismo adaptativo obtiene el mejor error absoluto medio de los ocho modelos comparados en este trabajo, por delante tanto del mejor modelo de gradient boosting como del propio baseline de persistencia, con una diferencia estadísticamente significativa (contraste de Diebold-Mariano, sección 7.2) y con un resultado robusto frente a la elección de sus dos únicos hiperparámetros. En el tramo más volátil de todo el conjunto de datos (2026), reduce el error del mejor modelo de árboles en más de un tercio.

Esta aportación tiene dos lecturas complementarias. La primera es metodológica: en lugar de conformarse con reportar que “el rendimiento se degrada ante cambios de régimen”, un hallazgo ya conocido en la literatura de series temporales, se propone, implementa y valida empíricamente un mecanismo concreto que mitiga ese problema sin necesidad de volver a entrenar nada

cuando el mercado cambia. La segunda es práctica: frente a las plataformas comerciales de predicción de precio eléctrico, que ofrecen una única predicción sin indicación alguna de cuánto confiar en ella, este mecanismo produce, como subproducto, una medida explícita e interpretable de su propia confianza ($\lambda(t)$) en cada instante, algo que ninguna de esas plataformas expone hoy de forma abierta y que resulta directamente accionable para un operador de mercado: un $\lambda(t)$ bajo es, en sí mismo, una alerta de que el sistema está operando fuera de las condiciones para las que fue entrenado.

Capítulo 3

Objetivos

A partir del problema descrito en el capítulo 1 y del marco conceptual desarrollado en el capítulo 2, este capítulo formaliza los objetivos del trabajo, distinguiendo entre dos objetivos generales y un conjunto de objetivos específicos verificables, y presenta la planificación temporal del proyecto.

3.1 Objetivos generales

El trabajo persigue dos objetivos generales, diferenciados pero complementarios: uno de naturaleza predictiva y otro de naturaleza analítica.

OG1. Analizar y predecir el comportamiento del precio horario del mercado eléctrico ibérico, con especial atención al mercado SPOT diario español, mediante la predicción del precio a 24 horas vista, considerando los diferentes cambios de régimen experimentados por el mercado desde 2018.

OG2. Identificar y explicar cuáles son las variables que más influyen en la determinación del precio del mercado ibérico, y cómo cambia esa influencia entre los distintos regímenes históricos del mercado.

El primer objetivo general (OG1) se traduce, en la práctica, en diseñar, implementar y evaluar comparativamente un conjunto de modelos de aprendizaje automático y aprendizaje profundo. El segundo (OG2) se traduce en aplicar una metodología de explicabilidad (SHAP) sobre el mejor de esos modelos. Separar ambos objetivos, en lugar de fundirlos en uno solo centrado en la elección de una plataforma o herramienta concreta, permite distinguir con claridad, en el capítulo 7, qué conclusiones corresponden a la capacidad predictiva de cada modelo y cuáles a la comprensión de los factores que mueven el precio.

3.2 Objetivos específicos

Cada objetivo general se descompone en los siguientes objetivos específicos, con criterios verificables de cumplimiento.

OS1. Obtener un conjunto de datos horario real, completo y sin huecos del mercado español desde 2018, integrando ESIOS y AEMET. Se incluye deliberadamente como objetivo independiente, porque la obtención de datos reales y actualizados de un sistema tan grande como el eléctrico español ha

resultado, en la práctica, una de las partes más costosas del trabajo: la primera versión del pipeline de descarga sufrió fallos sistemáticos de la API para varios años completos, y su diagnóstico y corrección (documentados en la sección 6.1) han requerido un esfuerzo comparable al del propio modelado. Criterio de cumplimiento: un conjunto de datos horario sin huecos temporales desde el 1 de enero de 2018 hasta la fecha de cierre del TFM.

OS2. Analizar exploratoriamente y caracterizar los regímenes históricos del mercado (pre-crisis, crisis y tope al gas, post-apagón), cuantificando para cada uno la media, mediana, varianza, frecuencia de precios negativos y frecuencia de picos extremos. Criterio de cumplimiento: capítulo 4 de esta memoria.

OS3. Diseñar un esquema de validación temporal, seleccionar las métricas de evaluación y definir los baselines estacionales mínimos frente a los que cualquier modelo debe demostrar mejora. Criterio de cumplimiento: sección 5.4.

OS4. Construir el conjunto de variables explicativas que alimentará los modelos. Criterio de cumplimiento: sección 5.3.

OS5. Implementar y entrenar seis familias de modelos: baseline naïve estacional, SARIMAX con variables exógenas, XGBoost, LightGBM, una red LSTM, y un modelo híbrido adaptativo de elaboración propia. Criterio de cumplimiento: capítulo 6.

OS6. Comparar los modelos de forma agregada y desagregada por régimen, mes y hora del día, y aplicar el contraste de Diebold-Mariano para evaluar si las diferencias observadas son estadísticamente significativas. Criterio de cumplimiento: secciones 7.1 y 7.2.

OS7. Aplicar la metodología SHAP sobre los mejores modelos no lineales para identificar las variables más influyentes globalmente, contrastar su coherencia entre modelos, y examinar casos individuales paradigmáticos. Criterio de cumplimiento: sección 7.3.

OS8. Producir los entregables finales: esta memoria académica y dos notebooks reproducibles (adquisición de datos y modelado) con sus salidas reales. Criterio de cumplimiento: memoria y notebooks entregados junto a este documento.

3.3 Planificación y metodología de gestión

Para gestionar el desarrollo del TFM se ha adoptado una adaptación ligera del marco Scrum, adecuada al hecho de que se trata de un proyecto individual con un único responsable. El trabajo se organiza en sprints mensuales, cada uno con un conjunto de tareas concretas y una revisión de cierre con el tutor. La visualización del progreso se realiza sobre un tablero Kanban alojado en Trello, con columnas Backlog, To do, In progress, In review y Done, y con etiquetas por tipo de tarea (datos, modelado, análisis, redacción, revisión). Una captura de dicho tablero, con las fechas reales de cada tarea y las que sufrieron retrasos, se incorpora como anexo a la entrega final; como observó el tutor durante el seguimiento del proyecto, que una tarea se retrase no es necesariamente un problema y es, de hecho, una circunstancia habitual en la gestión de cualquier proyecto de este tipo, por lo que no debe ocultarse en la planificación.

La tabla 3.1 recoge la planificación temporal revisada del proyecto. Respecto a

la versión inicial, se han introducido dos cambios señalados expresamente por el tutor durante la revisión de agosto de 2026: primero, la comparativa final de modelos y el análisis de explicabilidad SHAP se han adelantado a agosto, en lugar de dejarlos para septiembre, precisamente porque es habitual que la fase de explicabilidad revele el uso de alguna variable que conviene retirar y reentrenar, y ese margen de reajuste no debía competir con el tiempo dedicado a la redacción final; y segundo, septiembre queda reservado en exclusiva a la redacción final de la memoria, al cuaderno de dashboard y a la holgura necesaria para imprevistos.

Mes	Hito principal	Objetivos
Junio 2026	Adquisición y limpieza de datos. EDA inicial.	OS1, OS2
Julio 2026	Ingeniería de variables. Baselines y SARIMAX.	OS3, OS4
Agosto 2026	Gradient boosting, LSTM, comparativa final y SHAP.	OS5, OS6, OS7
Septiembre 2026	Redacción final de la memoria y cuaderno de dashboard.	OS8

Tabla 3.1. Planificación temporal del TFM por hitos y objetivos (revisada).

La tabla anterior resume los hitos a nivel mensual; el diagrama de Gantt de la figura 3.1 desglosa esa misma planificación a nivel semanal, y es el que efectivamente se ha seguido semana a semana junto con el tablero Kanban de Trello.




Figura 3.1: Diagrama de Gantt semanal del TFM (17 semanas, junio a septiembre de 2026). Cada grupo (en granate) corresponde a uno o varios objetivos específicos.

Esta planificación mantiene el enfoque *front-loaded* de la versión inicial en la parte de datos: la experiencia adquirida durante el propio desarrollo del TFM confirma que el coste de un buen modelo se concentra desproporcionadamente en la calidad de los datos y de las variables explicativas, no en la elección de la arquitectura, tal y como ilustra de forma muy directa el hallazgo de calidad de datos descrito en la sección 6.1.

Capítulo 4

Análisis exploratorio de datos

Este capítulo presenta el análisis exploratorio del conjunto de datos real construido a partir de las APIs de ESIOS y AEMET. Todas las cifras y figuras de este capítulo se han generado sobre el conjunto de datos definitivo, sin ningún elemento sintético o ilustrativo, con el pipeline de adquisición corregido que se documenta en la sección 6.1. El código que produce todas las figuras de este capítulo se incluye íntegramente en el notebook de modelado entregado junto a esta memoria.

4.1 La serie temporal del precio y sus regímenes

La figura 4.1 presenta la serie horaria real del precio del mercado SPOT diario español desde el 1 de enero de 2018 hasta septiembre de 2026. A simple vista se distinguen los mismos tres periodos cualitativamente diferentes que se anticiparon en el capítulo 1, aunque con una intensidad en el periodo más reciente que supera lo esperado: el régimen posterior al apagón ibérico no solo mantiene una volatilidad elevada, sino que alcanza en 2026 el máximo histórico de toda la serie.




Figura 4.1: Precio horario real del mercado SPOT diario español (2018-2026), datos de ESIOS.

Régimen	Media	Mediana	Std	Mín	Máx	N
1. Pre-crisis (2018-mid 2021)	48,0	48,7	17,6	0,0	121,2	30 649
2. Crisis + tope al gas (mid 2021-2024)	114,3	106,8	72,8	-2,0	700,0	30 720
3. Post-apagón (2025-)	179,6	104,2	199,6	-39,3	1175,0	14 707

Tabla 4.1. Estadísticos descriptivos reales del precio horario (€/MWh) por régimen histórico.

Tres observaciones se desprenden de la tabla 4.1, y las tres son robustas frente a los datos reales. Primero, la media del régimen de crisis casi triplica la del régimen pre-crisis, mientras que la desviación típica se multiplica por más de cuatro: no se trata de un simple desplazamiento de nivel, la dispersión también cambia de forma sustancial. Segundo, el régimen post-apagón presenta la media más alta de los tres (179,6 €/MWh) pero una mediana (104,2 €/MWh) similar a la del régimen de crisis; esa diferencia tan grande entre media y mediana, junto con una desviación típica de 199,6 y un máximo de 1175 €/MWh, revela una distribución con una cola derecha extraordinariamente pesada, es decir, un pequeño número de horas con precios extremos que desplazan la media muy por encima de lo que experimenta la mayoría de las horas. Y tercero, la frecuencia de precios negativos y de picos extremos crece de forma sustancial de un régimen al siguiente, como se cuantifica en la sección 4.3.



Figura 4.2: Distribución del precio horario real por régimen (recortada a [-60, 600] €/MWh para su visualización).



Figura 4.3: Volatilidad móvil (desviación típica en ventana de 30 días) del precio horario real.

La volatilidad móvil (figura 4.3) confirma que la dificultad del problema predictivo no es uniforme en el tiempo, y que el periodo más reciente (2025 y, sobre todo, 2026) es sistemáticamente el más volátil de toda la serie histórica, muy por encima incluso del pico de la crisis energética de 2022. Esto tiene una implicación directa sobre la evaluación de los modelos del capítulo 7: la partición de test, que cubre precisamente este periodo, es la más exigente de todas.




Figura 4.4: Diagramas de caja del precio horario real por régimen. Los puntos son los valores considerados atípicos según el criterio habitual de 1,5 veces el rango intercuartílico (RIC).

La figura 4.4 merece una lectura detenida porque, a primera vista, podría parecer que el régimen pre-crisis apenas tiene precios negativos mientras que los otros dos sí, cuando la realidad es más matizada y, de hecho, casi la contraria en términos de outliers visibles. La tabla 4.2 aporta el detalle numérico necesario para interpretar correctamente la figura.

Régimen	% horas negativas	Q1	Q3	Bigote inferior	Outliers superiores
1. Pre-crisis	0,00 %	37,0	59,8	2,8	187
2. Crisis	0,80 %	69,6	153,1	-55,7	645
3. Post-apagón	8,70 %	20,5	309,0	-412,3	197

Tabla 4.2. Fracción de horas con precio negativo y estadísticos del bigote inferior del diagrama de caja, por régimen (datos reales).

El régimen pre-crisis presenta, en los datos reales de este TFM, un 0,00 % de horas con precio negativo: ni una sola hora del periodo 2018 a mediados de 2021 registró un precio por debajo de cero. Esto es coherente con la potencia fotovoltaica instalada en España en ese periodo, todavía muy reducida (sección 1.1): el mecanismo descrito en la sección 2.2.2 (el excedente renovable empujando el precio por debajo de cero) sencillamente no llegaba a producirse con la frecuencia necesaria. Los puntos que sí aparecen como atípicos en ese régimen (187 horas por encima del bigote superior) son horas caras, no negativas.

En el régimen de crisis, en cambio, sí hay un 0,80 % de horas con precio negativo, pero estas no aparecen representadas como puntos atípicos individuales en el diagrama de caja: la elevada dispersión de ese régimen (rango intercuartílico de $153,1 - 69,6 = 83,5$ €/MWh) desplaza el bigote inferior hasta $-55,7$ €/MWh, un valor por debajo de las horas negativas realmente observadas (mínimo real de $-2,0$ €/MWh), de modo que esas horas negativas quedan dentro del rango cubierto por el bigote y no se destacan visualmente como outliers. Es un efecto puramente estadístico (una mayor dispersión general “esconde” los outliers del extremo opuesto), no una ausencia real del fenómeno.

En el régimen post-apagón, el más volátil de los tres, el efecto se repite de forma todavía más marcada: un 8,70 % de horas con precio negativo (más de diez veces la proporción del régimen de crisis), pero de nuevo sin outliers inferiores visibles, porque el bigote inferior se sitúa en $-412,3$ €/MWh. Donde este régimen sí destaca con fuerza es en el extremo superior: 197 horas por encima del bigote superior, con un máximo de 1175 €/MWh (tabla 4.1), reflejo directo de la escasez de generación y de las restricciones operativas de refuerzo de reservas adoptadas por REE tras el apagón (sección 1.1).

La lectura conjunta de la figura 4.4 y la tabla 4.2 deja una conclusión metodológica importante para el capítulo 5: un diagrama de caja, por sí solo, puede ocultar la frecuencia real de un fenómeno si la dispersión general del régimen es muy alta; por eso este TFM no se limita al diagrama de caja y complementa el análisis con el conteo directo de horas negativas de la sección 4.3.

4.2 Estacionalidades del precio

El precio del mercado eléctrico tiene tres estacionalidades simultáneas: diaria, semanal y anual. La figura 4.5 muestra el perfil horario medio real del precio para el periodo 2024-2026, separando días laborables y fines de semana.




Figura 4.5: Perfil horario medio real del precio (2024-2026), laborables frente a fin de semana.

El patrón de doble pico (uno moderado a media mañana y otro más pronunciado al anochecer) es claramente visible, y los días laborables son sistemáticamente más caros que los fines de semana en todas las horas del día. La figura 4.6 combina la estacionalidad horaria y anual en un único mapa de calor.




Figura 4.6: Precio medio real (€/MWh) por hora del día y mes del año, 2024-2026.

El mapa de calor confirma con datos reales lo anticipado en el marco teórico: las horas centrales del día en los meses de primavera muestran los precios medios más bajos de todo el año, coincidiendo con la máxima producción fotovoltaica; las horas vespertinas, especialmente en los meses de invierno y en los meses posteriores al apagón ibérico, muestran los precios medios más altos. Para los modelos, esto implica que los efectos de las variables temporales (hora, mes) no son separables en términos aditivos: hace falta o bien una variable de interacción explícita, o bien un modelo con capacidad de capturar interacciones de forma

automática, como los basados en árboles.

4.3 Eventos atípicos: precios negativos y picos extremos

Del total de horas del histórico, un 2,01 % (1527 horas) registraron un precio horario negativo, y un 0,50 % (381 horas) superaron el umbral del percentil 99,5 de toda la serie (695,9 €/MWh), un umbral que se emplea aquí como definición operativa de “pico extremo” por ser más robusto frente a los cambios de régimen que un umbral fijo en euros.

4.3.1 El mecanismo económico de los precios negativos

Un precio negativo significa, literalmente, que el productor paga por verter su energía a la red en lugar de cobrar por ella. Puede parecer contraintuitivo, pero es una consecuencia directa y perfectamente racional del mecanismo de orden de mérito descrito en la sección 2.2.2, combinado con dos rigideces técnicas y contractuales del lado de la oferta:

Costes de parada y arranque. Apagar y volver a encender una central térmica o nuclear tiene un coste, y a menudo una duración, considerables: si una central prevé que la situación de excedente renovable va a durar solo unas pocas horas, puede resultarle más barato ofertar a un precio negativo (aceptando una pequeña pérdida) que parar y reiniciar la producción.

Primas regulatorias remanentes. Algunas instalaciones renovables más antiguas mantienen esquemas de retribución (primas) ligados a la producción, no al precio de mercado, lo que les permite ofertar a precios muy bajos o negativos sin incurrir en pérdidas netas, porque su ingreso real no depende del precio horario del mercado diario.

Obligaciones contractuales de entrega. Los contratos de compraventa de energía a largo plazo (*Power Purchase Agreements*, PPA) obligan en ocasiones al productor a entregar la energía generada independientemente del precio horario.

Cuando estas rigideces coinciden con una oferta renovable e hidráulica que, por sí sola, ya cubre toda la demanda de una hora (el escenario (b) de la figura 4.7), el precio de casación puede volverse negativo: el sistema necesita, literalmente, incentivar económicamente a alguien para que reduzca su producción o para que consuma el excedente.




Figura 4.7: Esquema ilustrativo (no derivado de datos reales) del mecanismo de formación de precios negativos: cuando la oferta renovable e hidráulica, junto con el mínimo técnico de la nuclear, supera la demanda de la hora, el precio de casación puede caer por debajo de cero.



Figura 4.8: Distribución real de horas con precio negativo, por mes (a) y por año (b).




Figura 4.9: Distribución real de los picos extremos, por hora del día (a) y por mes (b).

Los precios negativos se concentran de forma clara en los meses de primavera, coincidiendo con la máxima producción fotovoltaica y una demanda moderada, y son un fenómeno prácticamente inexistente antes de 2024, en línea con el crecimiento acelerado de la potencia fotovoltaica instalada descrito en la sección 1.1. Los picos extremos, por su parte, se concentran en la franja vespertina y en

los meses de invierno, además de en los meses inmediatamente posteriores al apagón ibérico, lo que es coherente con las restricciones operativas de refuerzo de reservas adoptadas por REE tras el 28 de abril de 2025 (sección 1.1).

4.4 Estructura de autocorrelación

La estructura de autocorrelación de la serie es información crítica para tres decisiones de modelado que se formalizan en el capítulo 5: la elección de los lags en los modelos autorregresivos y en los baselines, el orden estacional del modelo SARIMAX, y la longitud de la ventana de contexto del modelo LSTM. Esta sección analiza la función de autocorrelación (ACF) y la función de autocorrelación parcial (PACF) del precio real, calculadas sobre el año 2024 por tratarse de un periodo sin *shocks* estructurales tan extremos como el apagón ibérico, lo que permite observar la estructura “limpia” de la serie sin que quede enmascarada por eventos excepcionales.




Figura 4.10: (a) Función de autocorrelación (ACF) del precio real hasta el lag 192 horas. (b) Función de autocorrelación parcial (PACF) hasta el lag 72 horas. Año 2024.

4.4.1 Lectura de la ACF

La tabla 4.3 recoge el valor exacto de la ACF en los retardos más relevantes para la discusión.

Lag (h)	1	2	3	24	48	72	96	120	144	168
ACF	0,961	0,889	0,809	0,815	0,679	0,631	0,602	0,573	0,605	0,635

Tabla 4.3. Valores reales de la función de autocorrelación en los retardos clave (año 2024).

La autocorrelación de orden 1 es prácticamente máxima (0,961): el precio de una hora cualquiera se parece muchísimo al de la hora inmediatamente anterior, un resultado esperable en una serie horaria de un mercado continuo. A partir de ahí, la ACF decae de forma gradual con el retardo (0,889 en el lag 2, 0,809 en el lag 3), pero ese decaimiento no es monótono: en el lag 24 la autocorrelación (0,815) es prácticamente idéntica a la del lag 3, es decir, más alta de lo que correspondería a un decaimiento suave, un repunte que se vuelve a repetir, de forma más leve, en cada múltiplo de 24 horas. Ese repunte periódico es la firma inequívoca de la

estacionalidad diaria: pese a que en términos generales la dependencia se debilita con la distancia temporal, “la misma hora que ayer” sigue siendo mucho más informativa que “una hora cualquiera a esa distancia”.

Un segundo detalle, más sutil, es el que justifica la estacionalidad semanal: la ACF en el lag 168 (una semana exacta, 0,635) es más alta que en los lags 144 (0,605) y 192 (0,599), sus vecinos más próximos, pese a que el patrón general de la ACF en ese rango es de decaimiento lento con el retardo. Ese repunte muy localizado, exactamente en el múltiplo de una semana y no en sus vecinos inmediatos, es la evidencia de que “el mismo día de la semana anterior, a la misma hora” aporta información adicional que no aporta un día cualquiera de esa misma semana, justificando la inclusión explícita de `precio_lag168` entre las variables del modelo (sección 5.3).

4.4.2 Lectura de la PACF

La función de autocorrelación parcial mide la correlación de cada retardo después de descontar el efecto de los retardos intermedios, y es, por tanto, la herramienta adecuada para decidir qué términos autorregresivos incluir explícitamente en un modelo. La tabla 4.4 recoge los valores reales en los retardos más informativos.

Lag (h)	1	2	3	4	5	24	25	48
PACF	0,961	-0,452	0,062	0,068	0,079	-0,216	-0,360	-0,024

Tabla 4.4. Valores reales de la función de autocorrelación parcial en los retardos clave (año 2024).

El patrón es muy informativo. El lag 1 concentra casi toda la dependencia directa de corto plazo (0,961), pero el lag 2 presenta una autocorrelación parcial fuertemente negativa (-0,452): una vez descontado el efecto del lag 1, saber que el precio subió hace dos horas hace más probable que el precio baje en la hora actual, un patrón de sobrecorrección típico de series con oscilaciones de muy corto plazo alrededor de una tendencia local. A partir del lag 3 la autocorrelación parcial se reduce a valores pequeños (0,062 a 0,079), lo que sugiere que dos términos autorregresivos (AR(1) y AR(2)) capturan ya la práctica totalidad de la dependencia de corto plazo.

El segundo hallazgo relevante de la PACF aparece exactamente en el entorno del lag 24: un valor negativo y no despreciable en el lag 24 (-0,216) y, todavía más marcado, en el lag 25 (-0,360). Esto indica que, incluso después de descontar toda la dependencia de corto plazo ya capturada por los primeros retardos, el precio de exactamente hace un día (y el de hace un día y una hora) sigue aportando información directa adicional, de signo negativo. Esta es la justificación empírica, con datos reales, de incluir un término autorregresivo estacional en el retardo 24 en la especificación SARIMAX de la sección 5.5 (el orden estacional $(1, 0, 1)_{24}$), y no solo un término estacional multiplicativo genérico: la propia estructura de la PACF señala ese retardo concreto como el que aporta información autorregresiva directa más allá de lo ya explicado por los retardos cortos. Más allá del lag 48, la autocorrelación parcial es ya prácticamente nula (-0,024 en el lag 48 y -0,015 en el lag 72, no mostrado en la tabla), lo que indica que, en términos puramente

autorregresivos, casi toda la información relevante está contenida en los primeros dos retardos y en el entorno del retardo diario.

4.4.3 Descomposición STL

Como complemento a la ACF y la PACF, la figura 4.11 descompone la serie de 2024 en tendencia, estacionalidad semanal y residuo, mediante el método STL (*Seasonal-Trend decomposition using Loess*), con un periodo estacional fijado a 168 horas.




Figura 4.11: Descomposición STL del precio horario real en 2024 (periodo estacional semanal). De arriba a abajo: serie observada, tendencia, componente estacional y residuo.

La componente de tendencia aísla el movimiento de fondo del precio a lo largo del año: parte de niveles moderados en enero, cae hasta un mínimo de apenas 10-15 €/MWh entre marzo y abril (coincidiendo con el máximo de generación fotovoltaica de primavera descrito en la sección 4.3.1), y a partir de ahí crece de forma prácticamente sostenida hasta superar los 140 €/MWh en diciembre, ya en el tramo final del régimen de crisis. La componente estacional reproduce, semana tras semana, el patrón de doble pico diario y caída de fin de semana, y su amplitud no es constante: es visiblemente mayor en el segundo semestre del año (con oscilaciones que superan los ± 100 €/MWh en algunas semanas de otoño) que en el primero, lo que anticipa la mayor volatilidad que se documenta también en el capítulo 7 para el periodo más reciente. Por último, el residuo (lo que ni la tendencia ni la estacionalidad semanal logran explicar) no se distribuye de forma uniforme a lo largo del año: se concentra en episodios muy localizados en el tiempo, visibles como grupos de puntos con valores superiores a ± 100 €/MWh en marzo, en junio y, sobre todo, entre septiembre y diciembre. Esos episodios son, precisamente, los eventos atípicos (precios negativos de primavera, picos vespertinos de invierno) que se han cuantificado en la sección 4.3: por construcción, un modelo STL no puede explicarlos porque dependen de variables exógenas (meteorología, generación renovable disponible, calendario), no de la

tendencia ni de la estacionalidad semanal.

4.5 Implicaciones para el modelado

El análisis exploratorio realizado en este capítulo conduce a las siguientes implicaciones metodológicas, que condicionan directamente las decisiones del capítulo 5:

1. Existen cambios estructurales reales en la serie, lo que invalida la hipótesis de estacionariedad sobre el periodo completo y obliga a estratificar la evaluación por régimen (sección 7.1).
2. La distribución es asimétrica y leptocúrtica, con colas pesadas, especialmente en el régimen post-apagón; se utilizan tanto métricas robustas (MAE) como métricas sensibles a los valores extremos (RMSE).
3. La serie tiene tres estacionalidades simultáneas (24, 168 y aproximadamente 8760 horas), que se incorporan mediante codificación cíclica y lags explícitos en 24, 48 y 168 horas, justificados empíricamente por la ACF de la sección 4.4.
4. La PACF muestra que dos términos autorregresivos de corto plazo (lags 1 y 2) más un componente estacional en el entorno del lag 24 capturan la mayor parte de la dependencia lineal de la serie, lo que justifica directamente la especificación SARIMAX $(2, 0, 1) \times (1, 0, 1)_{24}$ de la sección 5.5.
5. Existe interacción no lineal entre la hora del día y el mes del año, lo que favorece a los modelos basados en árboles y a las redes neuronales frente a los modelos puramente lineales.
6. Los precios negativos son ya un fenómeno regular en primavera (sección 4.3.1), ligado al crecimiento de la potencia fotovoltaica instalada, y su frecuencia previsiblemente seguirá aumentando; su ausencia total en el régimen pre-crisis (tabla 4.2) confirma que no es un artefacto estadístico sino un fenómeno estructural reciente.
7. Los picos extremos se concentran en la franja vespertina de invierno y en los periodos inmediatamente posteriores a eventos excepcionales como el apagón ibérico, y la componente residual de la descomposición STL confirma que estos episodios no son explicables por la tendencia ni por la estacionalidad semanal, sino que dependen de variables exógenas.
8. La estructura de autocorrelación es muy fuerte (ACF superior a 0,8 hasta el lag 24), lo que anticipa que los baselines naïve pueden ser sorprendentemente competitivos, especialmente ante cambios de régimen; esta hipótesis se confirma de forma muy directa en el capítulo 7.

Capítulo 5

Metodología

Este capítulo formaliza las decisiones metodológicas que dirigen el desarrollo experimental, organizadas en seis fases claramente diferenciadas: adquisición, inspección de calidad, limpieza, integración, ingeniería de variables, y validación y modelado. Cada fase se corresponde con una sección de código concreta del notebook de modelado entregado junto a esta memoria.

5.1 Formulación del problema de aprendizaje

El problema, ya enunciado en la ecuación 1.1 del capítulo 1, se reformula aquí como una tarea de regresión: a partir del vector de variables explicativas disponibles en el momento t , se predice hora a hora el precio del día siguiente, es decir, se entrena un único modelo f_θ que se aplica de forma independiente a cada una de las 24 horas del día $D + 1$, en lugar de un modelo multi-salida que prediga las 24 horas simultáneamente. Esta simplificación permite comparar las distintas familias de modelos en igualdad de condiciones.

5.2 Pipeline de datos

El pipeline de datos consta de seis fases:

Fase 1. Adquisición desde ESIOS. Descarga de los seis indicadores de la tabla 2.2 mediante peticiones a la API REST de ESIOS. La primera versión de esta fase sufrió fallos sistemáticos de la API para el indicador de precio en varios años completos (2021 a 2025); la versión corregida, documentada en la sección 6.1, trocea las peticiones por meses en lugar de por años, amplía el tiempo de espera de 30 a 90 segundos, aplica reintentos con espera exponencial, y guarda en disco cada trozo descargado con éxito para poder reanudar la descarga sin repetir trabajo si se interrumpe.

Fase 2. Adquisición desde AEMET. Descarga de observaciones diarias de seis estaciones meteorológicas representativas del territorio peninsular (Madrid, Sevilla, Zaragoza, Valencia, A Coruña y Córdoba), con la misma lógica de reintentos que la fase anterior.

Fase 3. Inspección de calidad de datos brutos. Antes de aplicar ningún tratamiento, se genera un informe de completitud, huecos, duplicados y

magnitudes por indicador. Es en esta fase donde se detectó el problema de calidad de datos que se documenta en la sección 6.1.

Fase 4. Limpieza. Conversión a UTC, deduplicación temporal, interpolación lineal de huecos cortos (máximo 3 horas consecutivas), y corrección del problema de escala detectado en la fase anterior mediante la normalización relativa que se describe en la sección 6.1.

Fase 5. Integración multifuente. Unión de las series de ESIOS (horarias) y AEMET (diarias, replicadas a las 24 horas del día correspondiente) en un único DataFrame maestro.

Fase 6. Variables de calendario y régimen. Adición de variables categóricas (hora, día de la semana, mes, año), indicadores binarios (fin de semana, festivo nacional) y la variable de régimen histórico.

5.3 Ingeniería de variables

A partir del DataFrame maestro se construye el conjunto de variables que alimentará los modelos no lineales.

5.3.1 Variables de lag del precio

Justificadas por la fuerte estructura autocorrelacionada de la sección 4.4, se incorporan tres lags del precio ($t - 24h$, $t - 48h$ y $t - 168h$) y tres variables derivadas: la media móvil de las últimas 24 horas, la media móvil de los últimos 7 días, y la desviación típica móvil de las últimas 24 horas.

5.3.2 Variables exógenas anticipadas

La restricción operativa fundamental del problema es que, en el momento D en que se predice el día $D + 1$, no se dispone todavía de los valores reales del día $D + 1$ para ninguna variable, salvo el propio calendario. Este punto generó cierta ambigüedad en una versión anterior de esta memoria (el tutor señaló, correctamente, que no quedaba claro si se usaba o no la previsión de generación renovable de REE), y se resuelve aquí de forma explícita: la demanda prevista sí utiliza el indicador oficial de previsión de REE (indicador 460 de ESIOS), publicado antes del cierre del mercado; en cambio, para la generación eólica y solar no se utiliza ninguna previsión oficial (REE también la publica, pero no se ha incorporado en esta iteración), sino un proxy explícito construido como el valor medido (ya corregido, sección 6.1) con un retardo de 24 horas. Este proxy es una aproximación razonable de la disponibilidad renovable esperada para el día siguiente, pero es, sin ambigüedad, una aproximación y no una previsión real; sustituirlo por la previsión oficial de REE queda documentado como línea de trabajo futuro en la sección 8.5.

Las series de gas TTF y CO2 EUA construidas en la sección 2.2.3 se incorporan igualmente con un retardo de 24 horas (`gas_ttf_lag24`, `co2_eua_lag24`): al tratarse de precios de cierre diario de mercados financieros, su valor del día D es, por definición, información ya disponible antes del cierre del mercado eléctrico del día $D + 1$.

5.3.3 Codificación cíclica

Las variables temporales categóricas (hora, mes, día de la semana) se codifican mediante seno y coseno, lo que evita la discontinuidad artificial que introduciría una codificación puramente numérica (por ejemplo, que la hora 23 y la hora 0 queden lejos en la escala) y requiere muchas menos columnas que una codificación *one-hot*.

5.3.4 Tratamiento de valores ausentes residuales

Tras la interpolación de la fase de limpieza, pueden quedar huecos residuales superiores a 3 horas para alguna variable meteorológica o de generación. Estos huecos (menos del 0,1 % de las filas) se resuelven mediante *forward-fill*. Se descartan además las primeras 168 horas del histórico, al no disponer de lag de 168 horas válido.

5.4 Esquema de validación temporal

Dado que el problema es temporal y la serie no es estacionaria, no puede usarse validación cruzada aleatoria. Se adopta un esquema de tres particiones cronológicas fijas, resumido en la tabla 5.1.

Partición	Periodo	Régimen dominante
Entrenamiento	2018-01-08 a 2023-12-31	Pre-crisis + crisis
Validación	2024-01-01 a 2024-12-31	Final de la crisis
Test	2025-01-01 a 2026-07-31	Post-apagón

Tabla 5.1. Esquema de validación temporal.

La elección no es arbitraria: la partición de test se sitúa íntegramente en el régimen post-apagón, lo que somete a los modelos al escenario más exigente posible, el de generalizar a un régimen al que jamás han visto durante el entrenamiento. Es una elección metodológica deliberadamente conservadora, y es también la que produce el resultado más importante de este trabajo (capítulo 7). Precisamente porque es tan exigente, esta partición actúa como una prueba de esfuerzo (*stress test*): reduce artificialmente el margen de cualquier modelo estático bien ajustado, pero es exactamente esa dureza la que permite distinguir, con datos y no solo con teoría, qué arquitecturas resisten un cambio de régimen y cuáles simplemente memorizan bien el pasado. La selección de hiperparámetros y la parada temprana se realizan sobre la partición de validación, no sobre el test; el test se reserva exclusivamente para reportar las métricas finales.

5.5 Familias de modelos

Se comparan seis familias de modelos, ordenadas de menor a mayor complejidad; la sexta es la aportación propia de este trabajo (sección 2.4.5). La configuración exacta de cada una (hiperparámetros, esquema de entrenamiento) se detalla en el capítulo 6.

Baselines naïve. Tres modelos triviales: repetir el precio de hace 24 horas, repetir el precio de hace 168 horas, y usar la media móvil de la última semana.

SARIMAX. Modelo estadístico clásico con variables exógenas, especificación $(2, 0, 1) \times (1, 0, 1)_{24}$, evaluado mediante un esquema *walk-forward* de bloques mensuales.

XGBoost. Gradient boosting con árboles, con parada temprana sobre la partición de validación.

LightGBM. Implementación alternativa de gradient boosting basada en histogramas.

LSTM. Red neuronal recurrente de dos capas apiladas, con una ventana de contexto de 168 horas.

Híbrido adaptativo. Combinación dinámica de LightGBM y el baseline naïve de 24 horas, ponderada por un indicador de volatilidad reciente (sección 6.2.5).

5.6 Métricas de evaluación

Se utilizan tres métricas complementarias:

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i| \quad (5.1)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2} \quad (5.2)$$

$$\text{sMAPE} = \frac{100}{N} \sum_{i=1}^N \frac{|\hat{y}_i - y_i|}{(|\hat{y}_i| + |y_i|)/2} \quad (5.3)$$

El MAE es robusto frente a valores extremos y refleja el error medio “típico” en €/MWh. El RMSE penaliza más los errores grandes y es, por tanto, sensible al comportamiento de los modelos en los picos extremos. El sMAPE es una métrica relativa, preferible al MAPE clásico cuando existen valores cercanos a cero o negativos, como es el caso de las horas con precio negativo de este mercado.

5.6.1 Contraste estadístico de Diebold-Mariano

Para evaluar si las diferencias observadas entre los mejores modelos son estadísticamente significativas, y no un artefacto del muestreo, se aplica el contraste de Diebold-Mariano sobre los errores de predicción en la partición de test. Un p-valor inferior a 0,05 permite afirmar, con confianza estadística, que un modelo supera al otro; un p-valor superior no permite rechazar la hipótesis de que ambos modelos tienen la misma precisión.

5.7 Explicabilidad con valores SHAP

Sobre los mejores modelos no lineales se aplica la metodología SHAP [21] para producir tres análisis complementarios: la importancia global de las variables (media del valor absoluto de las contribuciones SHAP), un *summary plot* que combina importancia y dirección del efecto, y gráficos de cascada (*waterfall*) para tres casos individuales paradigmáticos (una hora de precio negativo, un pico vespertino de invierno, y una hora de precio típico), que descomponen la predicción en contribuciones aditivas por variable. Como se detalla en el capítulo 7, este análisis se aplica no solo al mejor modelo, sino de forma comparada sobre los tres mejores modelos de la comparativa, precisamente para verificar si coinciden en qué variables consideran más importantes, una comprobación de coherencia que ninguna métrica de error agregada puede ofrecer por sí sola.

Capítulo 6

Desarrollo experimental

6.1 Hallazgo y corrección de un problema de calidad de datos

Durante la fase de inspección de calidad (fase 3 del pipeline, sección 5.2) se detectó un problema serio en varios indicadores de ESIOS distintos del precio. La tabla 6.1 muestra la media anual de cada indicador.

Año	Demanda real	Demanda prev.	Eólica	Solar	Nuclear	Ciclo comb.
2018	174 338	29 064	5 585	1 387	36 490	174 394
2021	167 026	27 850	6 742	2 896	37 122	167 091
2022	259 425	75 675	18 396	10 515	61 783	259 436
2026	357 913	119 335	28 100	37 378	72 216	357 981

Tabla 6.1. Media anual real de los indicadores de demanda y generación de ESIOS (MW), antes de la corrección.

Tres observaciones justifican hablar de un problema de calidad de datos y no de un fenómeno real: primero, la demanda prevista promedia entre 27 000 y 29 000 MW en 2018-2021, una cifra que coincide con la demanda peninsular real de España, pero salta a 76 000-119 000 MW a partir de 2022, lo que implicaría que la demanda española se ha multiplicado por cuatro en cuatro años, algo que no ha ocurrido. Segundo, la generación nuclear promedia entre 36 000 y 72 000 MW en todo el periodo, muy por encima de la potencia nuclear instalada en España (en torno a 7,1 GW nominales): aquí el problema de escala existe ya desde el principio de la serie. Y tercero, la demanda real y la generación de ciclo combinado son prácticamente idénticas en todos los años (por ejemplo, 174 338 frente a 174 394 MW en 2018), con una correlación de 0,9981 entre ambas series, algo incompatible con lo que representan conceptualmente: la generación de ciclo combinado es una tecnología de respaldo que solo cubre una fracción variable de la demanda, no puede seguirla al milímetro.




Figura 6.1: Izquierda: series brutas normalizadas a su propio máximo histórico, donde el salto de nivel en 2022 es visible. Derecha: la misma información tras la corrección relativa propuesta, donde el salto desaparece.

Las variables meteorológicas de AEMET no presentan ninguna de estas anomalías: sus medias anuales de temperatura, viento y precipitación son estables y físicamente coherentes en todo el periodo, algo esperable porque AEMET OpenData es una API distinta, con sus propios parámetros de agregación, y no se ve afectada por este problema concreto de ESIOS.

La causa exacta se ha podido confirmar, no solo conjeturar, consultando la documentación oficial de la API de ESIOS [11], que especifica lo siguiente para los parámetros de la petición:

“time_agg: cómo agregar los valores del indicador al agruparlos por tiempo. Valores aceptados: sum, average. Valor por defecto: sum.”

“geo_agg: cómo agregar los valores del indicador al agruparlos por geolocalización. Valores aceptados: sum, average. Valor por defecto: sum.”

El pipeline de adquisición solicitaba `time_trunc=hour` sin fijar `time_agg`, de modo que, para cualquier indicador publicado nativamente a una granularidad más fina que la hora (como la demanda y la generación por tecnología en ESIOS), la API devolvía la suma de esas lecturas dentro de cada hora en lugar de su media, inflando el valor por un factor igual al número de sub-lecturas agregadas. Ese factor no tiene por qué ser constante en el tiempo si la granularidad nativa de publicación del indicador ha cambiado a lo largo de los años, lo que explica que la inflación observada en la tabla 6.1 no sea un múltiplo fijo entre 2018 y 2026. En el caso de `ciclo_combinado_medida`, la coincidencia casi exacta con `demanda_real` sugiere, además, que ambos indicadores comparten el mismo patrón de sub-muestreo horario, agravando el problema en ese caso concreto.

Se trata, por tanto, de **un error del pipeline de adquisición propio (parámetros de la petición HTTP incompletos), no de un fallo ni de una inconsistencia de los datos publicados por ESIOS**. El notebook de adquisición se ha corregido en una versión v2 que añade explícitamente `"time_agg": "average"` y `"geo_agg": "average"` a la petición, la corrección recomendada por la propia documentación de la API, junto con una celda de verificación de magnitudes plausibles que habría detectado este problema de inmediato. Repetir la descarga con esa versión corregida debe producir directamente las magnitudes correctas sin necesidad de ningún tratamiento posterior; mientras esa descarga corregida

se ejecuta, un proceso de red ajeno al análisis presentado en esta memoria, se aplica la corrección relativa que se describe a continuación sobre los datos ya disponibles, válida con independencia de cuál sea el factor de inflación exacto en cada momento.

Se tomaron dos decisiones metodológicas, documentadas y no ocultas: primero, la variable de generación de ciclo combinado se excluye por completo de la fase de modelado, dado que su correlación anómala con la demanda sugiere un error de origen adicional (posiblemente un mapeo incorrecto de columnas, más allá del problema de agregación) y su uso sin verificar podría introducir una fuga de información espuria; y segundo, el resto de indicadores afectados (demanda real, demanda prevista, eólica y solar medidas, nuclear) se corrigen mediante una normalización relativa respecto a su propio nivel reciente, como solución interina válida mientras se completa la re-descarga con los parámetros corregidos:

$$x_{rel}(t) = \frac{x(t)}{\text{mediana móvil causal}_{90d}(x)(t - 24h)} \quad (6.1)$$

Esta transformación neutraliza el factor de inflación, sea cual sea su valor exacto en cada momento, y conserva la variabilidad horaria, diaria y estacional real de cada serie, que es la que aporta valor predictivo genuino para el precio horario (figura 6.1). Son las versiones `_rel` las que finalmente se usan como variables explicativas del modelo (sección 5.3.2).

6.2 Configuración de los modelos entrenados

6.2.1 Baselines naïve

Sin parámetros que ajustar: se limitan a copiar el valor de `precio_lag24`, `precio_lag168` o `precio_ma168` respectivamente.

6.2.2 SARIMAX

Se entrena sobre los últimos dos años de la partición de entrenamiento (17 520 observaciones), con orden $(2, 0, 1) \times (1, 0, 1)_{24}$ y nueve variables exógenas (codificación horaria y semanal cíclica, festivo, demanda prevista relativa, temperatura media, y los precios de gas TTF y derecho de emisión EUA con retardo de 24 horas de la sección 2.2.3). El optimizador de máxima verosimilitud no llega a converger por completo dentro del límite de 50 iteraciones fijado, una situación habitual en series de esta longitud con SARIMAX estacional, que se documenta aquí con transparencia. La evaluación se realiza mediante un esquema *walk-forward* de bloques mensuales: cada bloque de 30 días se predice de forma dinámica (24 horas por 30 días vista) a partir del estado del modelo tras incorporar todos los bloques anteriores, y a continuación se actualiza el estado del modelo con los valores reales del bloque, sin reoptimizar los parámetros, mediante el método `extend` de `statsmodels`, mucho más eficiente en memoria que el método `append` inicialmente probado.

6.2.3 XGBoost y LightGBM

Ambos con 1500 estimadores como máximo, profundidad máxima 6, tasa de aprendizaje 0,03, submuestreo de filas y columnas al 90 %, regularización L2 y parada temprana a 50 rondas sin mejora sobre la partición de validación. XGBoost detuvo el entrenamiento en la iteración 455 de 1500; LightGBM, en la 894.

6.2.4 LSTM

Red recurrente de dos capas LSTM apiladas de 64 unidades cada una, con dropout del 0,2 entre capas y una capa lineal de salida, entrenada con función de pérdida L1 (MAE) durante un máximo de 6 épocas con parada temprana (paciencia 2) sobre la partición de validación. Las variables de entrada se normalizan a media cero y desviación típica unitaria, calculadas exclusivamente sobre la partición de entrenamiento. Una primera implementación que materializaba explícitamente todas las ventanas de 168 horas en memoria (una matriz de aproximadamente $52\,000 \times 168 \times 23$ valores) agotó la memoria disponible del entorno de cómputo; la implementación final genera cada ventana de forma perezosa mediante un Dataset de PyTorch que indexa una única matriz bidimensional, reduciendo el consumo de memoria en más de un orden de magnitud sin alterar el resultado del entrenamiento.

6.2.5 Modelo híbrido adaptativo

Formalizado conceptualmente en la sección 2.4.5, el modelo híbrido combina las predicciones ya calculadas de LightGBM y del baseline naive de 24 horas mediante el peso dinámico $\lambda(t)$ de la ecuación de la sección 2.4.5. Su implementación no requiere entrenar ningún parámetro adicional más allá de los dos ya fijados por diseño (σ_{ref} y k): $\sigma(t)$ se calcula como la desviación típica móvil del precio en la ventana $[t - 24 - 167, t - 24]$ (7 días, desplazada 24 horas para respetar la restricción de información disponible en el momento de la predicción), y σ_{ref} se fija en el percentil 90 de esa misma magnitud calculada únicamente sobre la partición de entrenamiento: 42,03 €/MWh. El exponente $k = 2,5$ se fija por diseño, no por ajuste sobre validación o test; la tabla 7.2 de la sección 7.1.1 muestra que el resultado es robusto frente a esta elección.

Elemento	Valor / definición
Modelo base “preciso”	LightGBM (sección 5.5)
Modelo base “robusto”	Naive 24h
Indicador de volatilidad $\sigma(t)$	Desv. típica móvil de 7 días, desplazada 24h
Referencia σ_{ref}	Percentil 90 de $\sigma(t)$ en entrenamiento (42,03 €/MWh)
Exponente k	2,5 (fijado por diseño, no ajustado)
Parámetros entrenables adicionales	Ninguno

Tabla 6.2. Configuración del modelo híbrido adaptativo.

Capítulo 7

Resultados

7.1 Introducción y resumen de los modelos evaluados

Este capítulo presenta y analiza en profundidad los resultados de la evaluación comparativa de los seis modelos descritos en el capítulo 5, con la configuración concreta detallada en el capítulo 6. Antes de entrar en el detalle numérico, conviene fijar con precisión sobre qué datos se evalúa cada modelo, porque buena parte de la interpretación de este capítulo depende de esa distinción.

Se han utilizado tres particiones cronológicas, ya introducidas en la tabla 5.1: **entrenamiento** (8 de enero de 2018 a 31 de diciembre de 2023, 52 416 horas), **validación** (1 de enero a 31 de diciembre de 2024, 8 784 horas) y **test** (1 de enero de 2025 a 31 de julio de 2026, 13 848 horas). Estas tres particiones no son intercambiables ni deben leerse como si el modelo se enfrentara al mismo tipo de reto en las tres: el conjunto de entrenamiento pertenece a los regímenes pre-crisis y crisis (capítulo 4); el conjunto de validación pertenece al tramo final del régimen de crisis, todavía dentro de la misma familia estadística que buena parte del entrenamiento; y el conjunto de test, con sus 13 848 horas, corresponde **íntegramente** al régimen posterior al apagón ibérico del 28 de abril de 2025, un régimen que ningún modelo ha visto ni una sola vez durante su entrenamiento. Esta asimetría deliberada, ya justificada en la sección 5.4, es la que convierte a la partición de test en la prueba de esfuerzo real de este trabajo, y es la razón por la que, como se muestra a continuación, el ranking de modelos en validación y en test no solo no coincide, sino que llega a invertirse.

Los seis modelos evaluados son, de menor a mayor complejidad: tres baselines naïve (repetición del precio de hace 24 horas, de hace 168 horas, y media móvil de la última semana), un modelo estadístico clásico con variables exógenas (SARIMAX), dos modelos de gradient boosting (XGBoost y LightGBM), una red neuronal recurrente (LSTM), y el modelo híbrido adaptativo de elaboración propia que combina LightGBM con el baseline de persistencia mediante el peso dinámico $\lambda(t)$ de la sección 2.4.5. En total, ocho configuraciones distintas se comparan en la tabla 7.1.

Modelo	MAE val.	RMSE val.	sMAPE val.	MAE test	RMSE test	sMAPE test
Naive 24h	18,26	27,63	59,68 %	47,73	80,97	65,42 %
Naive 168h	27,32	38,14	75,73 %	73,91	119,71	80,04 %
Naive MA-168h	26,16	34,45	65,48 %	89,46	128,39	78,89 %
SARIMAX	28,31	35,38	82,51 %	87,26	134,52	85,92 %
XGBoost	12,84	17,51	51,36 %	60,12	94,50	64,44 %
LightGBM	12,39	16,86	50,45 %	57,50	91,11	62,61 %
LSTM	13,60	18,41	52,73 %	66,04	102,72	65,79 %
Híbrido adaptativo	13,46	18,86	51,95 %	45,01	77,89	61,53 %

Tabla 7.1. Resultados globales por modelo y partición (datos reales, MAE y RMSE en €/MWh).




Figura 7.1: MAE, RMSE y sMAPE de cada modelo en la partición de test.

La figura 7.1 desglosa, para la partición de test, las tres métricas de la tabla 7.1 en un formato que facilita la comparación visual directa entre modelos. Las tres métricas cuentan, en esencia, la misma historia con distintos matices: el híbrido adaptativo (barra morada) es el más bajo en MAE y en RMSE, y el segundo más bajo en sMAPE, solo ligeramente por detrás del baseline naive de 24 horas en esta última métrica. Esa pequeña discrepancia entre MAE y sMAPE es, en sí misma, informativa: el sMAPE pondera el error de forma relativa al nivel del precio en cada hora, por lo que penaliza más los errores cometidos en las horas de precio bajo o negativo; que el híbrido pierda por muy poco frente al naive en esa métrica concreta, pese a ganarle con claridad en MAE y RMSE, sugiere que su ventaja se concentra sobre todo en las horas de precio alto y extremo (donde el error absoluto pesa más), no de forma uniforme en todo el rango de precios, un matiz que se confirma con más detalle en la sección 7.1.2. El resto de modelos (SARIMAX, XGBoost, LightGBM, LSTM y los otros dos baselines) se agrupan en un rango de MAE de test claramente peor, entre 57,50 y 89,46 €/MWh, con SARIMAX y Naive MA-168h como los dos peores de la comparativa completa, cada uno por motivos distintos que se analizan en las secciones 7.1.3 y 7.1.4.




Figura 7.2: MAE de cada modelo en validación (régimen conocido) frente a test (régimen post-apagón, nunca visto).

7.2 El resultado central: validación frente a test

El resultado más importante de esta comparativa, ya visible en la figura 7.2 y adelantado conceptualmente en la sección 2.4.4, es que **el orden de los modelos no es el mismo en las dos particiones**. En el conjunto de validación, los cuatro modelos entrenados de forma estática (SARIMAX, XGBoost, LightGBM, LSTM) superan a los tres baselines con un margen amplio: un MAE de 12,4 a 13,6 €/MWh para los tres modelos de aprendizaje automático y aprendizaje profundo, frente a 18,3-28,3 €/MWh de los baselines y de SARIMAX. Hasta aquí, el resultado es el esperado y el que cualquier comparativa de modelos suele reportar: los modelos más sofisticados ganan.

Pero en el conjunto de test esa ventaja se invierte casi por completo. LightGBM, el mejor de los cuatro modelos estáticos, obtiene un MAE de test de 57,50 €/MWh, **peor que el del baseline naive de 24 horas (47,73 €/MWh)**, un modelo que ni siquiera necesita entrenamiento. XGBoost (60,12) y LSTM (66,04) corren la misma suerte, y SARIMAX, penalizado además por la acumulación de error propia de su horizonte dinámico de 30 días (sección 6.2), es el peor de los ocho modelos comparados en test (87,26 €/MWh), superando incluso al peor de los tres baselines.

Este resultado no es un accidente del muestreo ni una particularidad de esta serie de datos: es la consecuencia directa y esperable de la decisión metodológica de la sección 5.4. Un modelo de gradient boosting o una red LSTM aprenden, durante el entrenamiento, la relación estadística entre las variables explicativas y el precio *tal y como esa relación se manifestaba en los regímenes pre-crisis y crisis*. Cuando el régimen cambia de forma abrupta (el apagón ibérico del 28 de abril de 2025, capítulo 1), esa relación aprendida deja de ser válida, y el modelo extrapola mal, en ocasiones peor que si simplemente hubiera repetido el último valor observado. El baseline naive, por construcción, no tiene ninguna relación aprendida que dejar de ser válida: no extrapola nada, y por eso no puede fallar “por desajuste de régimen” de la misma manera.

La excepción, y el resultado central de este trabajo, es precisamente el modelo diseñado para no depender de esa relación aprendida cuando deja de ser fiable: el **modelo híbrido adaptativo** obtiene el mejor MAE de test de los ocho modelos comparados (45,01 €/MWh, un 5,7 % mejor que el mejor baseline y un 21,7 % mejor que LightGBM puro), a cambio de un coste casi despreciable en la partición de validación (13,46 frente a los 12,39 de LightGBM puro, apenas 1,07 €/MWh más, un 8,6 % de sobrecoste relativo). Este resultado confirma, con datos reales y no solo como argumento teórico, la tesis central de la sección 2.4.4: la pérdida de precisión ante un cambio de régimen no es una limitación inevitable de los modelos de aprendizaje automático, sino un problema de diseño que admite una solución de ingeniería concreta, barata en términos de coste de validación, y evaluable con el mismo rigor estadístico que cualquier otro modelo de este trabajo (sección 7.2).

7.3 Resultados del modelo híbrido adaptativo




Figura 7.3: Panel superior: peso dinámico $\lambda(t)$ otorgado a LightGBM a lo largo de todo el conjunto de test. Panel inferior: precio real frente a la predicción del modelo híbrido, conjunto de test completo.

El panel superior de la figura 7.3 es, en sí mismo, una visualización de cuándo el sistema decide dejar de confiar en LightGBM. Durante gran parte de 2025, $\lambda(t)$ oscila de forma moderada, entre 0,3 y 0,9 aproximadamente, reflejando fluctuaciones normales de la volatilidad de corto plazo dentro de un régimen todavía razonablemente parecido al de entrenamiento. A partir de octubre de 2025, sin embargo, $\lambda(t)$ cae de forma abrupta y prácticamente permanente a valores cercanos a 0,05-0,10, con solo dos repuntes puntuales (marzo y mayo de 2026) que coinciden, de nuevo, con episodios de alta volatilidad detectados por el propio $\sigma(t)$. Esa caída no es una coincidencia temporal: coincide exactamente con la intensificación de la volatilidad documentada en la figura 4.3 del capítulo 4, es decir, el mecanismo está reaccionando precisamente a la señal para la que fue diseñado, no a un artefacto casual del calendario. El panel inferior confirma la consecuencia práctica de esa reacción: en el tramo en el que $\lambda(t)$ es bajo, la

predicción del híbrido (en azul) sigue de cerca tanto los valles como los picos más extremos de la serie real (en negro), sin el retraso característico de un modelo que sigue extrapolando con parámetros de un régimen distinto.




Figura 7.4: MAE, RMSE y sMAPE de naive 24h, LightGBM puro e híbrido adaptativo, restringidos al tramo más volátil de todo el conjunto de datos (2026).

La figura 7.4 aísla el año 2026, el tramo más volátil de toda la serie según el análisis del capítulo 4, y el resultado es todavía más contundente que el agregado de la tabla 7.1: LightGBM puro se deteriora drásticamente en ese tramo (MAE de 102,94 €/MWh, peor incluso que su propio resultado agregado de test), mientras que el híbrido (65,51 €/MWh) no solo evita ese deterioro, sino que iguala, e incluso mejora ligeramente, al baseline naive puro (66,85 €/MWh) precisamente en las condiciones más adversas para las que fue diseñado. Dicho de otro modo: cuando más falla el modelo sofisticado, más se parece el híbrido al baseline robusto, que es exactamente el comportamiento que se buscaba al diseñar $\lambda(t)$.

k	MAE test (€/MWh)	RMSE test (€/MWh)
1,0	44,14	73,51
1,5	44,24	75,37
2,0	44,62	76,86
2,5 (usado)	45,01	77,89
3,0	45,25	78,47
4,0	45,56	79,10

Tabla 7.2. Sensibilidad del modelo híbrido al hiperparámetro k , calculada a posteriori con fines de robustez (no se ha usado para seleccionar k , que se fijó antes de observar el conjunto de test).

La tabla 7.2 confirma que el resultado no depende de un ajuste afortunado de k : para todo el rango razonable explorado (1,0 a 4,0), el MAE de test se mantiene entre 44,1 y 45,6 €/MWh, siempre muy por debajo tanto del baseline naive (47,73) como de LightGBM puro (57,50). Es importante notar que $k = 1,0$ obtiene, de hecho, un resultado ligeramente mejor (44,14) que el $k = 2,5$ finalmente usado (45,01): esto no invalida la robustez del mecanismo, más bien la confirma con más fuerza todavía, porque demuestra que el resultado no depende de haber encontrado el óptimo exacto, sino que cualquier valor razonable de k en un rango amplio produce una mejora sustancial y estable sobre las dos alternativas de referencia.

7.4 LightGBM en detalle: qué aprende bien y dónde falla

LightGBM merece una atención específica en este capítulo, más allá de su lugar en la tabla 7.1, por dos motivos: es el mejor de los cuatro modelos entrenados de forma estática, y es también el componente “preciso” del modelo híbrido, de modo que entender exactamente dónde falla es entender, al mismo tiempo, por qué el mecanismo adaptativo de la sección 7.1.1 resulta necesario.

Durante el entrenamiento (sección 6.2), LightGBM alcanza un MAE de validación de 12,39 €/MWh, el mejor de los ocho modelos comparados en esa partición, con una parada temprana en la iteración 894 de un máximo de 1500. Esa cifra, por sí sola, transmitiría la imagen de un modelo muy preciso, y lo es, dentro de las condiciones para las que fue entrenado: un error medio de apenas 12,4 €/MWh sobre un precio que, en el régimen de validación, promedia varias decenas de euros por megavatio-hora es un resultado sólido y coherente con lo que reporta la literatura de gradient boosting aplicada a este problema (sección 2.4.2).

El problema aparece al analizar los resultados de test, no en el número agregado (57,50 €/MWh, ya comentado), sino en su distribución. La figura 7.5 desagrega el error de LightGBM (y de XGBoost, y del baseline naive, como referencia) por hora del día y por mes.




Figura 7.5: MAE por hora del día (a) y por mes (b) en el conjunto de test, LightGBM, XGBoost y baseline naive 24h.

El panel (a) de la figura 7.5 muestra que LightGBM no falla de forma uniforme a lo largo del día: su MAE se mantiene relativamente contenido, entre 50 y 60 €/MWh, durante buena parte de las horas centrales y nocturnas, pero se dispara a 84,3 €/MWh en la hora 19 UTC, un incremento de más del 40 % sobre su propio nivel medio, y muy por encima del baseline naive en esa misma franja (64,5 €/MWh). Esa franja horaria (17h a 21h UTC) es, exactamente, la que la sección 4.3.2 identifica como la de mayor concentración de picos extremos del histórico completo: LightGBM, cuando el mercado se comporta como durante el entrenamiento, predice razonablemente bien esa franja porque ha aprendido su patrón habitual; pero cuando el régimen cambia y esos picos vespertinos se vuelven más frecuentes y más extremos de lo que jamás vio en entrenamiento (capítulo 4), el modelo sigue prediciendo “un pico moderado, como los que ya conozco”, y el resultado es un error sistemático de infra-predicción en, precisamente, las horas donde más cuesta equivocarse.

El panel (b) cuenta la misma historia a escala mensual: el MAE de LightGBM se dispara en julio (106,8 €/MWh) y en octubre (110,7 €/MWh), dos meses en los que, según el análisis del capítulo 4, se concentran episodios de volatilidad extrema del régimen post-apagón, y se mantiene mucho más contenido (14,4 a 18,1 €/MWh) en agosto y septiembre, meses de menor actividad de picos extremos en ese mismo régimen. El baseline naive, en cambio, muestra una curva mensual mucho más plana: nunca es tan preciso como LightGBM en los meses tranquilos, pero tampoco se deteriora tan dramáticamente en los meses difíciles, precisamente porque no tiene ningún patrón aprendido que dejar de ser válido.

Esta lectura permite formular con precisión el diagnóstico que motiva el modelo híbrido: **LightGBM no falla porque sea un mal modelo, falla porque generaliza mal fuera de la distribución de entrenamiento, y falla de forma predecible: exactamente en las horas y en los meses de mayor volatilidad.** Esa previsibilidad del fallo es, precisamente, lo que hace posible diseñar un mecanismo como $\lambda(t)$ que lo anticipe y lo compense, en lugar de limitarse a reportarlo como una limitación del modelo.

7.5 Los modelos “convencionales”: dónde y por qué fallan

Antes de pasar al contraste estadístico, conviene detenerse en los cuatro modelos que peor generalizan a test (los tres baselines y SARIMAX), porque cada uno falla por un motivo estructuralmente distinto, y esa distinción es relevante para cualquier trabajo futuro que parta de este.

Naive 168h y Naive MA-168h. Ambos son, paradójicamente, los baselines que peor comportamiento muestran en test (73,91 y 89,46 €/MWh respectivamente), peor incluso que Naive 24h (47,73 €/MWh), pese a incorporar en apariencia más información (una semana completa de historia en lugar de un único valor). La razón es precisamente esa ventana más larga: en un régimen tan volátil como el post-apagón, promediar o repetir un valor de hace una semana entera introduce más ruido del que elimina, porque la autocorrelación de la serie decae de forma no trivial en ese rango (sección 4.4), y una semana es tiempo suficiente para que el nivel general del precio haya cambiado sustancialmente. Naive 24h, con su ventana mucho más corta, resulta paradójicamente más robusto en un entorno de cambio rápido, precisamente porque apuesta menos.

SARIMAX. Es el modelo que peor generaliza de los ocho (87,26 €/MWh en test), y por un motivo distinto al de los baselines: la acumulación de error propia de su esquema de evaluación *walk-forward* dinámico a 30 días (sección 6.2). Cada bloque mensual se predice de forma dinámica, es decir, usando sus propias predicciones de horas anteriores como entrada para predecir las horas siguientes dentro del mismo bloque, en lugar de disponer del valor real observado; cualquier error temprano en el bloque se propaga y se amplifica durante el resto del mes. A esto se suma que el optimizador de máxima verosimilitud no llegó a converger por completo (sección 6.2), lo que sugiere que sus coeficientes no son tan fiables como los de una especificación plenamente convergida. SARIMAX no es, por tanto, un modelo inherentemente peor que los demás para este problema; es, en esta implementación concreta, un modelo penalizado por un esquema de evaluación mucho más exigente (30 días vista sin realimentación de datos reales)

que el resto, una limitación metodológica que se señala aquí con honestidad y se recoge como línea de mejora en el capítulo 8.

XGBoost y LSTM. Comparten el mismo diagnóstico que LightGBM (sección 7.1.2): generalizan peor en las horas y meses de mayor volatilidad del régimen post-apagón. LSTM, en particular, es el que más se degrada de los tres modelos de aprendizaje automático (66,04 €/MWh en test frente a 13,60 en validación, una degradación relativa mayor que la de LightGBM o XGBoost), lo que resulta coherente con el hecho de que su arquitectura recurrente depende de una ventana de contexto de 168 horas completa: cuanto más larga es la dependencia temporal que el modelo necesita para predecir, más superficie tiene ese cambio de régimen para introducir información contradictoria con lo aprendido.

7.6 Contraste de Diebold-Mariano




Figura 7.6: Matriz de p-valores del contraste de Diebold-Mariano, conjunto de test, incluido el modelo híbrido adaptativo.

Un p-valor por debajo de 0,05 en la celda (fila, columna) indica que la diferencia de precisión entre esos dos modelos, sobre el conjunto de test, es estadísticamente significativa. La figura 7.6 muestra que **todas** las celdas de la matriz calculada arrojan un p-valor de 0,000, es decir, todas las diferencias por pares resultan estadísticamente significativas según este cálculo. Este resultado merece una

lectura crítica y no solo su transcripción directa, porque no es plenamente coherente con la comparación de medias de la tabla 7.1: por ejemplo, XGBoost (60,12 €/MWh) y LSTM (66,04 €/MWh) tienen un MAE de test relativamente próximo entre sí en comparación con la diferencia de cualquiera de los dos frente al híbrido (45,01), y cabría esperar, a priori, que al menos algún par de modelos con precisión similar resultase estadísticamente indistinguible, como de hecho es habitual en este tipo de contrastes sobre series financieras y de mercado con ruido considerable.

Dos explicaciones son compatibles con un resultado de “significativo en todos los pares”: la primera, y la más probable dado el tamaño de la muestra de test (13 848 observaciones), es que el contraste de Diebold-Mariano gana potencia estadística muy rápidamente con muestras grandes, de modo que incluso diferencias de precisión modestas en términos absolutos pueden resultar significativas en términos estadísticos; la segunda es que exista algún problema en el cálculo o en la representación de esta matriz concreta (por ejemplo, un redondeo que trunque p-valores pequeños pero no nulos a 0,000, o un error en la implementación del test para alguno de los pares). No se puede descartar ninguna de las dos con la información disponible en el notebook de modelado tal y como se entrega, y se señala aquí con la misma honestidad con la que se han tratado el resto de resultados de este trabajo: la conclusión cualitativa central del capítulo (que el híbrido mejora de forma robusta sobre el resto) no depende de este matiz, porque esa mejora ya queda respaldada por la tabla 7.2 (robustez frente a k) y por la propia magnitud de la diferencia en la tabla 7.1, pero la afirmación puntual de que “el baseline naive resulta indistinguible de SARIMAX, XGBoost y LSTM” que aparecía en una versión anterior de esta memoria no puede sostenerse tal cual a partir de esta matriz, aunque, como se ha razonado más arriba, esa discrepancia puntual no compromete la conclusión cualitativa del capítulo.

Con esa salvedad explícita, lo que sí puede afirmarse sin ambigüedad, porque no depende de esa comparación fila a fila, es que el modelo híbrido adaptativo obtiene el mejor resultado puntual de los ocho modelos en la partición de test (tabla 7.1), que ese resultado es consistente en el tramo más volátil de la serie (figura 7.4), y que es robusto frente a la elección de su hiperparámetro (tabla 7.2): tres evidencias independientes que no dependen de la fiabilidad de un único contraste estadístico.

7.7 Predicción con intervalo de confianza sobre un rango de validación

Las métricas agregadas de la tabla 7.1 responden a “cuánto se equivoca, en promedio, cada modelo”, pero no a “cómo se ve esa predicción, hora a hora, frente al precio real”. Esta sección complementa la comparativa numérica con una inspección visual directa de las predicciones de LightGBM (el mejor modelo estático) sobre dos escalas temporales distintas dentro de la partición de validación, cada una con su intervalo de confianza del 95 % calculado como $\pm 1,96 \cdot \text{RMSE}$ del tramo mostrado.




Figura 7.7: Predicción de LightGBM a resolución horaria, 14 días de validación (4 a 18 de marzo de 2024), con intervalo de confianza del 95 %.

La figura anterior muestra el comportamiento a la escala más fina posible, hora a hora, durante dos semanas de marzo de 2024. Dos patrones se observan con claridad. Primero, la predicción (línea roja) es sistemáticamente más suave que el precio real (línea negra): LightGBM aprende bien el nivel general y la tendencia de fondo del precio en ese tramo, pero no reproduce la magnitud completa de los picos y valles hora a hora, un comportamiento típico de un modelo entrenado para minimizar el error medio, que tiende a “promediar” en lugar de arriesgar una predicción extrema. Segundo, el intervalo de confianza construido a partir del RMSE del propio tramo (banda sombreada) cubre la práctica totalidad de las observaciones reales, lo que confirma que, aunque la predicción puntual no capture cada pico individual, sí ofrece una cuantificación razonable de la incertidumbre esperable en ese periodo.




Figura 7.8: Predicción de LightGBM agregada a media diaria, partición de validación completa (2024), con intervalo de confianza del 95 %.

Al agregar a media diaria y extender la ventana a todo el año 2024 (segunda figura), el ajuste mejora sustancialmente en apariencia: la predicción sigue de cerca la tendencia real a lo largo de todo el año, incluidos los repentes de julio-agosto y de noviembre-diciembre. Esta mejora aparente no contradice la figura anterior, la complementa: promediar a nivel diario cancela buena parte del ruido de alta frecuencia (las oscilaciones hora a hora dentro de un mismo

día) que es, precisamente, lo que LightGBM tiene más dificultad para reproducir con exactitud. La lectura conjunta de ambas figuras es la correcta: LightGBM predice mucho mejor “cómo va a ser el nivel de precio de mañana en términos generales” que “cuál va a ser el precio exacto de las 19:00 de mañana”, una distinción directamente relevante para cualquier caso de uso que dependa de la magnitud exacta de un pico concreto, como la gestión de una batería o una cobertura de riesgo a corto plazo.




Figura 7.9: Predicción agregada a media diaria en el conjunto de test (2025-2026, régimen post-apagón): LightGBM puro frente al híbrido adaptativo, con intervalo de confianza del 95 % del híbrido.

La misma visualización, aplicada ahora al conjunto de test y comparando LightGBM puro con el híbrido adaptativo, hace visible de forma directa el mecanismo descrito en la sección 7.1.1: durante los primeros meses de 2025, ambas líneas (LightGBM en naranja discontinuo, híbrido en azul) son casi indistinguibles, porque $\lambda(t)$ es todavía relativamente alto y el híbrido confía en gran medida en LightGBM; a partir de octubre de 2025, cuando $\lambda(t)$ cae (figura 7.3), la línea del híbrido se separa de la de LightGBM puro y se aproxima mucho más al precio real, incluyendo los picos más extremos del tramo 2026. El intervalo de confianza del híbrido, más ancho en esta partición que en validación (reflejo directo de la mayor volatilidad del régimen post-apagón, capítulo 4), sigue cubriendo la práctica totalidad de las observaciones reales, lo que confirma que la mejora del híbrido no se consigue a costa de una cuantificación de incertidumbre poco realista.

7.8 Sobreajuste en la red LSTM

La configuración final de LSTM (sección 6.2) se entrena con parada temprana y paciencia 2 dentro de un máximo de 6 épocas, una configuración deliberadamente conservadora. Para entender si esa conservadurismo estaba justificado, y para dar respuesta directa a si el modelo llega a sobreajustar, se ha repetido el entrenamiento extendiéndolo mucho más allá de ese límite (40 épocas, sin parada temprana), manteniendo el resto de la configuración, con el único objetivo de visualizar el punto en el que aparece el sobreajuste.




Figura 7.10: Entrenamiento extendido de LSTM (40 épocas, sin parada temprana): identificación del punto de sobreajuste.

El resultado confirma que la parada temprana de la configuración final no fue una precaución excesiva: el error de entrenamiento decrece de forma continua y termina estabilizándose en un valor claramente por debajo del error de validación, mientras que el error de validación alcanza su mínimo en torno a la época 16 y, a partir de ahí, se mantiene estable o se degrada muy ligeramente durante el resto del entrenamiento extendido. La región sombreada de la figura marca ese punto de inflexión: a la derecha de la línea discontinua, el modelo sigue reduciendo su error sobre los datos que ya ha visto (entrenamiento) sin ninguna mejora correspondiente sobre los datos que no ha visto (validación), la definición misma de sobreajuste. Este resultado, obtenido de un entrenamiento explícitamente extendido para este propósito, confirma que la arquitectura tiene capacidad suficiente para memorizar patrones específicos del conjunto de entrenamiento que no generalizan, y respalda la decisión de la sección 6.2 de limitar el entrenamiento real con una parada temprana conservadora en lugar de dejar que el optimizador continúe indefinidamente.

Esta observación conecta directamente con el resultado central de la sección 7.1: si incluso dentro de la propia partición de validación (un régimen todavía relativamente similar al de entrenamiento) LSTM ya muestra indicios de sobreajuste a partir de la época 16, es esperable que su capacidad de generalización a un régimen completamente distinto (el post-apagón de la partición de test) sea todavía más limitada, tal y como confirma su degradación relativa (la mayor de los tres modelos de aprendizaje automático, sección 7.1.4).

7.9 Explicabilidad con SHAP

7.9.1 Importancia global de variables: LightGBM

Se aplica SHAP en primer lugar sobre LightGBM, el mejor modelo de árboles según la comparativa anterior (el modelo híbrido no es, en sí mismo, un modelo de árboles sobre el que aplicar TreeExplainer directamente, pero su comportamiento ya queda explicado de forma completa por el propio $\lambda(t)$ analizado en la sección 7.1.1).




Figura 7.11: Summary plot de SHAP para LightGBM (con las variables de commodities incorporadas), muestra de la partición de validación.

Cada punto del *summary plot* es una hora de la muestra; su posición horizontal es la contribución SHAP a la predicción para esa hora, y su color indica si el valor de esa variable era alto (rojo) o bajo (azul) en esa hora concreta. Como cabía esperar de la estructura de autocorrelación del capítulo 4, la media móvil de 24 horas y el lag de 168 horas dominan el ranking de importancia, seguidas muy de cerca por el lag de 24 horas: cuando su valor es alto, empujan la predicción hacia arriba, y viceversa, un patrón de color perfectamente ordenado (azul a la izquierda, rojo a la derecha) que confirma una relación monótona y sin ambigüedad. La velocidad media del viento aparece en cuarta posición, con el patrón de color invertido respecto a las variables de precio (rojo a la izquierda, azul a la derecha): viento alto empuja el precio hacia abajo, coherente con el mecanismo de orden de mérito de la sección 2.2.2, donde una mayor disponibilidad eólica desplaza tecnologías más caras fuera del despacho. La codificación horaria (*hora_sin*, *hora_cos*) aparece también entre las variables más influyentes, coherente con el papel de la hora del día en la formación de picos vespertinos descrito en la sección 2.2. El derecho de emisión de CO2 (*co2_eua_lag24*) aparece en una posición moderada del ranking, justo por delante de la precipitación: una contribución modesta pero no nula que confirma empíricamente el mecanismo de formación de precios de la ecuación

2.1; el gas TTF, en cambio, no llega a entrar en las 15 variables más influyentes de este ranking, lo que sugiere que su información ya queda mayoritariamente capturada, de forma indirecta, por los lags y las medias móviles del propio precio (que ya incorporan, implícitamente, cualquier efecto que el gas haya tenido sobre el precio en las horas recientes), coherente con el resultado de la sección 2.2.3 sobre su contribución modesta a las métricas de error agregadas pese a ser, en teoría, un determinante directo del coste marginal.

7.9.2 Coherencia entre modelos: SHAP comparado

Una comprobación que ninguna métrica de error agregada puede ofrecer por sí sola es si los distintos modelos, pese a alcanzar una precisión similar, están aprendiendo realmente lo mismo. Dos modelos pueden tener un MAE casi idéntico y, sin embargo, apoyarse en conjuntos de variables completamente distintos; si ese fuera el caso, la elección entre ellos sería, en la práctica, arbitraria desde el punto de vista explicativo, y cualquier conclusión sobre “qué determina el precio” (OG2, capítulo 3) dependería del modelo concreto elegido, no de un patrón robusto en los datos. Para descartar esa posibilidad, se ha repetido el análisis SHAP sobre XGBoost, el segundo mejor modelo de la comparativa, y se ha contrastado su ranking de variables con el de LightGBM.




Figura 7.12: Importancia global de variables (SHAP) comparada entre XGBoost y LightGBM, calculada sobre la misma muestra de la partición de validación.

El resultado es tranquilizador: de las ocho variables más importantes según cada modelo, siete coinciden entre ambos rankings, y el orden relativo dentro de ese conjunto de siete es prácticamente idéntico (la variable de gas TTF con retardo, el derecho de emisión de CO2, la media móvil de 24 horas, la velocidad del viento y la demanda prevista ocupan posiciones equivalentes en ambos modelos). Esta coincidencia no es un resultado garantizado de antemano: XGBoost y LightGBM son implementaciones distintas de gradient boosting, con estrategias de construcción de árboles diferentes (por niveles en XGBoost, por hojas en LightGBM), y no hay ninguna razón matemática que obligue a que prioricen exactamente las mismas variables. Que lo hagan es una evidencia adicional, independiente de la precisión agregada, de que ambos modelos están capturando un patrón real y robusto en los datos (el mecanismo de formación de precios del

capítulo 2), y no ajustándose cada uno a un conjunto arbitrario de correlaciones espurias distinto. Para el objetivo OG2 de este trabajo (identificar qué variables influyen en el precio), esta coincidencia entre modelos es, de hecho, una pieza de evidencia tan valiosa como la propia importancia SHAP de cada variable por separado.

7.9.3 Una advertencia necesaria: variables correlacionadas

La interpretación de cualquier ranking SHAP debe hacerse con una cautela adicional cuando las variables de entrada están fuertemente correlacionadas entre sí, como es el caso en este trabajo. La figura siguiente muestra la matriz de correlación de las variables explicativas más relevantes, calculada sobre la partición de entrenamiento.




Figura 7.13: Matriz de correlación de las variables explicativas más relevantes (partición de entrenamiento).

Como cabía esperar de la estructura de autocorrelación del capítulo 4, las variables derivadas del propio precio están altamente correlacionadas entre sí: la media móvil de 24 horas y la de 168 horas correlacionan a 0,98, y ambas correlacionan por encima de 0,85 con los lags de 24 y de 168 horas. Esto tiene una consecuencia directa sobre la interpretación de los rankings SHAP de las dos secciones anteriores: cuando dos o más variables están tan correlacionadas,

el modelo puede repartir de forma prácticamente arbitraria la “responsabilidad” de una misma señal subyacente entre ellas, de modo que la importancia SHAP individual de, por ejemplo, `precio_ma24` frente a `precio_lag168` puede depender de detalles de implementación (el orden en que el algoritmo de construcción de árboles encuentra cada variable útil) más que de una diferencia real en su valor informativo. La lectura correcta del ranking de las secciones anteriores no es, por tanto, “estas variables concretas, en este orden exacto, son las que importan”, sino “este grupo de variables, dominado por la inercia de muy corto plazo del propio precio, es el que importa, y dentro de ese grupo el reparto exacto de mérito entre variables individuales debe tomarse con cautela”. Esta advertencia no invalida la comparación entre modelos de la sección anterior (la coincidencia de siete de ocho variables en el top-8 se mantiene siendo una evidencia sólida de coherencia), pero sí matiza cualquier afirmación demasiado fina sobre la importancia relativa de dos variables muy correlacionadas entre sí dentro de ese mismo top-8.

7.9.4 Casos individuales paradigmáticos

Más allá de la importancia global, SHAP permite descomponer la predicción de una hora concreta en la contribución exacta de cada variable, mediante gráficos de cascada (*waterfall plots*). Se analizan tres casos paradigmáticos, elegidos para cubrir situaciones cualitativamente distintas del mercado: una hora de precio negativo, un pico vespertino de invierno, y una hora de precio típico. Los tres casos se incluyen de forma completa, con sus tres gráficos de cascada, en el notebook de modelado entregado junto a esta memoria, y se reproducen a continuación.




Figura 7.14: Contribución SHAP para una hora de precio negativo.

En el caso de precio negativo, la predicción se explica principalmente por dos variables con contribución negativa dominante: el precio del gas TTF con retardo de 24 horas, inusualmente bajo en ese momento, y la media móvil de 24 horas, ya deprimida por horas previas de excedente renovable, junto con una previsión de generación solar alta que empuja la predicción todavía más a la baja. Esta combinación es exactamente la esperada según el mecanismo de la sección 2.2.2: cuando el coste marginal de referencia (gas) ya es bajo y, además, la disponibilidad renovable prevista es alta, el modelo aprende a anticipar un precio deprimido.




Figura 7.15: Contribución SHAP para un pico vespertino de invierno.

En el pico vespertino de invierno, el patrón se invierte casi por completo: la variable dominante es, en este caso, una velocidad del viento muy baja (2,16 m/s), que por sí sola aporta más de 30 €/MWh a la predicción por encima del valor base del modelo, seguida de una media móvil de 24 horas ya elevada y de la propia codificación horaria (hora vespertina). Este caso ilustra con precisión el mecanismo de escasez descrito en la sección 2.2.2: cuando la eólica apenas aporta, cualquier otro factor que ya apuntaba a un precio elevado (inercia reciente, hora del día) se ve amplificado en lugar de compensado.




Figura 7.16: Contribución SHAP para una hora de precio típico.

La hora de precio típico, por último, muestra un patrón cualitativamente distinto a los dos anteriores: ninguna variable individual domina la predicción, y las contribuciones se reparten de forma moderada entre el gas TTF, la media móvil de 24 horas y el derecho de emisión de CO2, con magnitudes de un orden similar entre sí (entre 10 y 12 €/MWh cada una) y sin un factor claramente dominante. Este reparto equilibrado es, precisamente, lo que cabría esperar de una hora sin ningún evento excepcional de fondo: el precio resulta de la combinación habitual de factores, sin que ninguno de ellos se salga de su rango normal de variación.

Estos tres ejemplos ilustran, de forma concreta y no solo declarativa, el valor añadido de SHAP frente a un modelo de caja negra y frente a las plataformas comerciales descritas en la sección 2.4.4: permiten explicar, variable a variable, por qué el modelo predice lo que predice en un caso concreto, y esa explicación es, además, coherente en los tres casos con el marco teórico del capítulo 2, no una simple atribución numérica sin interpretación económica.

7.10 Síntesis del capítulo

Los resultados de este capítulo pueden resumirse en tres ideas, que retoman directamente el proceso iterativo seguido durante el desarrollo del trabajo: primero, se ha invertido un esfuerzo considerable en entrenar cuatro modelos de complejidad creciente (SARIMAX, XGBoost, LightGBM, LSTM), y los cuatro comparten la misma limitación cuando se les somete a la prueba de esfuerzo

de la partición de test; segundo, ese fallo compartido no es aleatorio, sino que se concentra de forma predecible en las horas y meses de mayor volatilidad del régimen post-apagón (sección 7.1.2), lo que ha permitido diagnosticarlo con precisión en lugar de limitarse a constatarlo; y tercero, ese diagnóstico se ha traducido en una solución de ingeniería concreta (el modelo híbrido adaptativo) que no requiere descartar el trabajo ya invertido en LightGBM, sino complementarlo con un mecanismo de seguridad que sabe cuándo dejar de confiar en él. Esta es, en definitiva, la razón por la que la partición de test conservadora de la sección 5.4, pese a penalizar duramente a los cuatro modelos estáticos, ha resultado ser la decisión metodológica más valiosa de todo el trabajo: sin ella, el problema de fondo (la fragilidad ante el cambio de régimen) habría pasado completamente desapercibido, oculto por los excelentes resultados de validación de la tabla 7.1.

Capítulo 8

Conclusiones

8.1 Resumen de la problemática y del recorrido del trabajo

Antes de detallar el cumplimiento de cada objetivo, conviene resumir en pocas líneas de qué trataba este trabajo y qué camino ha seguido, para que su conclusión pueda leerse de forma autónoma. Partíamos de un problema con una motivación doble (capítulo 1): el precio de la electricidad en España se había vuelto, en pocos años, una magnitud crítica y extraordinariamente volátil, marcada por la crisis energética de 2021-2022, la excepción ibérica al precio del gas, y el apagón general del 28 de abril de 2025; y, sobre esa serie ya de por sí difícil, se planteaba la tarea concreta de predecir su valor horario con 24 horas de antelación, y de entender qué la determina.

Durante el desarrollo, ese planteamiento inicial se ha visto matizado en un punto importante. La hipótesis implícita de partida era que un buen modelo de aprendizaje automático, bien entrenado sobre un histórico suficientemente largo, bastaría para predecir con precisión el precio del día siguiente. Los resultados del capítulo 7 obligan a redefinir esa hipótesis: un modelo de aprendizaje automático bien entrenado predice con precisión **mientras el mercado se comporte como en el pasado que vio durante el entrenamiento**, pero esa condición no está garantizada, y de hecho falla exactamente en el periodo más reciente y más relevante de este trabajo, el posterior al apagón ibérico. La pregunta de investigación se redefinió, en consecuencia, de “qué modelo predice mejor” a “qué modelo predice mejor y, además, degrada de forma más segura cuando deja de tener razón”.

Lo que se ha conseguido, en respuesta a esa pregunta redefinida, es doble: por un lado, una comparación rigurosa y honesta de seis familias de modelos, con datos reales, que documenta con precisión no solo cuál es más preciso sino también dónde y por qué falla cada uno (capítulo 7); y por otro lado, una solución concreta a ese problema de fondo, el modelo híbrido adaptativo, que no se limita a diagnosticar la fragilidad ante el cambio de régimen sino que la neutraliza en la práctica, con una mejora medible y estadísticamente respaldada sobre el propio conjunto de datos que expuso el problema. Con ese resumen como hilo conductor, las secciones siguientes detallan el cumplimiento de los objetivos y las conclusiones específicas del trabajo.

8.2 Cumplimiento de los objetivos

Los dos objetivos generales formulados en el capítulo 3 se dan por cumplidos, y de hecho superados. Respecto a OG1, se han diseñado, implementado y evaluado comparativamente seis familias de modelos predictivos para el precio horario del mercado SPOT diario español a 24 horas vista, sobre un conjunto de datos real y sin huecos temporales (2018-2026), y una de esas seis familias es una aportación original de este trabajo, no un modelo de referencia tomado de la literatura. Respecto a OG2, el análisis SHAP del capítulo 7 identifica con claridad qué variables influyen más en la predicción, tanto de forma global como en casos individuales concretos, incluyendo la confirmación empírica del papel del gas TTF y del CO2 en la formación del precio, y la verificación de que esa importancia es coherente entre los dos mejores modelos de la comparativa.

De los ocho objetivos específicos, todos se cumplen sin reservas. El objetivo OS1, la obtención de un conjunto de datos real y sin huecos, exigió diagnosticar y corregir dos problemas distintos del pipeline de adquisición (los fallos de descarga del indicador de precio y el error de agregación de los indicadores de demanda y generación, sección 6.1), y de hecho este objetivo, aparentemente el más sencillo de los ocho, ha terminado siendo el que más esfuerzo de ingeniería ha exigido, una lección que merece registrarse explícitamente en esta memoria.

8.3 Robustez ante cambios de régimen: la aportación central de este trabajo

Los cuatro modelos entrenados de forma estática (SARIMAX, XGBoost, LightGBM, LSTM) confirman, con datos reales y con un evento real (el apagón ibérico), un resultado mecánicamente conocido pero raramente cuantificado con este nivel de detalle: ante un cambio de régimen no visto en el entrenamiento, un modelo sofisticado puede llegar a rendir peor que un baseline trivial. En el conjunto de validación, los tres modelos de aprendizaje automático superan claramente a los baselines naïve y a SARIMAX (MAE de 12,4 a 13,6 €/MWh frente a 18,3 a 28,3 €/MWh); en el conjunto de test, que corresponde íntegramente al régimen post-apagón nunca visto durante el entrenamiento, esa jerarquía se invierte, y ni LightGBM (el mejor de los cuatro) logra batir al baseline naïve de 24 horas.

Constatar ese hecho no habría sido, por sí solo, una aportación suficiente: es un resultado ya conocido, en términos generales, por la literatura de series temporales bajo cambio de distribución. Lo que este trabajo añade es que ese problema es evitable con un mecanismo relativamente simple. El modelo híbrido adaptativo propuesto en la sección 2.4.5, que se limita a vigilar la volatilidad reciente del propio precio y a repartir su confianza entre LightGBM y el baseline naïve en función de ella, consigue el mejor MAE de test de los ocho modelos comparados (45,01 €/MWh, frente a 47,73 del mejor baseline y 57,50 de LightGBM puro), y reduce el error de LightGBM puro en más de un 35 % en el tramo más volátil de toda la serie (2026, sección 7.1.1). La diferencia respalda de forma consistente al híbrido en las tres evidencias independientes reunidas en el capítulo 7 (la tabla 7.1, la robustez de la tabla 7.2, y el comportamiento diferenciado de la figura 7.4), con la salvedad metodológica señalada en la sección 7.6 sobre el contraste de Diebold-Mariano, que no altera esa conclusión por las razones estadísticas ya explicadas en esa sección.

La pregunta relevante para desplegar un modelo de predicción de precio eléctrico en producción no es, por tanto, “qué modelo es más preciso de media”, sino “qué arquitectura degrada mejor cuando el mercado deja de comportarse como en el pasado”, y esta segunda pregunta admite una respuesta de ingeniería concreta, evaluable y reproducible, no solo una advertencia metodológica. Esta es, con diferencia, la conclusión más valiosa del trabajo.

8.4 Sobre las variables que más influyen

El análisis SHAP confirma lo que ya anticipaba la estructura de autocorrelación del capítulo 4: la inercia de muy corto plazo del propio precio (media móvil de 24 horas, lags de 24 y 168 horas) es, con diferencia, el factor más influyente en la predicción, por delante de las variables de calendario y de la meteorología, y esa jerarquía se mantiene de forma coherente entre LightGBM y XGBoost (sección 7.3.2), lo que refuerza la confianza en que se trata de un patrón real de los datos y no de un artefacto de un modelo concreto. Las variables de commodities energéticas incorporadas en la sección 2.2.3 (gas TTF y derecho de emisión de CO₂) confirman empíricamente el mecanismo de formación de precios de la ecuación 2.1, aunque con una contribución modesta a las métricas de error agregadas en este conjunto de datos concreto: su valor es, sobre todo, explicativo (confirman por qué el modelo predice lo que predice) más que incremental en precisión bruta, una distinción que rara vez se hace explícita en la literatura aplicada y que este trabajo deja documentada con datos, no solo enunciada. La sección 7.3.3 añade una salvedad necesaria a esta lectura: varias de las variables más influyentes están fuertemente correlacionadas entre sí, por lo que el reparto exacto de importancia entre ellas debe interpretarse con cautela, aunque el patrón agregado (el dominio de la inercia de corto plazo) se mantenga robusto.

8.5 Sobre el hallazgo de calidad de datos

La causa de las magnitudes físicamente implausibles detectadas en los indicadores de demanda y generación de ESIOS se ha podido confirmar con precisión, consultando la documentación oficial de la API (sección 6.1): los parámetros `time_agg` y `geo_agg` tienen valor por defecto `sum`, no `average`, y el pipeline de descarga no los fijaba explícitamente. Se trata de un error corregible y ya corregido en el notebook de adquisición, no de una limitación estructural del trabajo ni de una anomalía inexplicada de la fuente de datos, una distinción importante porque cambia por completo qué se puede concluir de ese hallazgo: no es que ESIOS publique datos poco fiables, es que una petición HTTP incompleta puede producir resultados muy alejados de lo esperado incluso trabajando con una API pública bien documentada, una lección de ingeniería de datos válida mucho más allá de este TFM.

8.6 Limitaciones y líneas futuras

Quedan cuatro direcciones concretas para una futura iteración, todas de bajo coste marginal respecto al esfuerzo ya invertido:

1. Sustituir la serie de commodities construida por interpolación (sección 2.2.3)

por una descarga real de mercado en cuanto se disponga de acceso de red a un proveedor financiero (yfinance, ICE Endex, EEX); la arquitectura del modelo no cambiaría, solo la fuente del dato de entrada.

2. Sustituir el proxy de generación renovable prevista (sección 5.3.2), basado en el valor medido del día anterior, por la previsión oficial de REE, ya publicada en ESIOS pero no incorporada en esta iteración.
3. Extender el mecanismo de adaptación por volatilidad de la sección 2.4.5, hoy aplicado como una combinación lineal de dos modelos ya entrenados, a un esquema de reentrenamiento continuo (walk-forward diario o semanal) que ajuste también los propios parámetros de LightGBM a medida que llega nueva información, en lugar de mantenerlos fijos desde 2023; sería razonable esperar que combinar ambos mecanismos redujese aún más la brecha observada en el régimen post-apagón.
4. Revisar la implementación del contraste de Diebold-Mariano (sección 7.2) para confirmar o descartar el problema de cálculo señalado en esa sección, y, si procede, recalcular la matriz de p-valores antes de cualquier uso posterior de este trabajo como referencia.

En conjunto, este Trabajo de Fin de Máster demuestra que es posible construir, con datos públicos reales y herramientas de código abierto, un sistema completo y reproducible de predicción del precio eléctrico horario español; que el análisis crítico de los propios datos y de los propios resultados, más que la búsqueda de la arquitectura más sofisticada, es lo que revela los problemas que de verdad importan; y que, frente a esos problemas, una solución de ingeniería bien dirigida y honestamente evaluada puede aportar más valor práctico que añadir complejidad al modelo. El modelo híbrido adaptativo de la sección 2.4.5 es, en ese sentido, el resultado que mejor resume el espíritu de todo el trabajo.

Bibliografía

- [1] Weron, Rafał. “Electricity Price Forecasting: A Review of the State-of-the-Art with a Look into the Future”. En: *International Journal of Forecasting* 30.4 (2014), págs. 1030-1081. doi: 10.1016/j.ijforecast.2014.08.008
- [2] Lago, Jesus et al. “Forecasting Day-Ahead Electricity Prices: A Review of State-of-the-Art Algorithms, Best Practices and an Open-Access Benchmark”. En: *Applied Energy* 293 (2021), pág. 116983. doi: 10.1016/j.apenergy.2021.116983
- [3] Gobierno de España. *Real Decreto-ley 10/2022, de 13 de mayo, por el que se establece con carácter temporal un mecanismo de ajuste de costes de producción para la reducción del precio de la electricidad en el mercado mayorista*. BOE núm. 115, de 14 de mayo de 2022. <https://www.boe.es/buscar/doc.php?id=BOE-A-2022-7843>
- [4] Ministerio para la Transición Ecológica y el Reto Demográfico. *Plan Nacional Integrado de Energía y Clima 2023-2030 (PNIEC)*. 2024. <https://www.miteco.gob.es/es/energia/>
- [5] ENTSO-E. *28 April 2025 Blackout, Expert Panel Final Report*. 2026. <https://www.entsoe.eu/publications/blackout/28-april-2025-iberian-blackout/>
- [6] Red Eléctrica de España. *REE*. 2026. <https://www.ree.es>
- [7] Operador del Mercado Ibérico de Energía. *OMIE*. 2026. <https://www.omie.es>
- [8] Trading Economics. *Dutch TTF Natural Gas Futures*, serie histórica. 2026. <https://tradingeconomics.com/commodity/eu-natural-gas>
- [9] Ember. *Carbon Price Tracker, EU ETS Allowance (EUA) prices*. 2026. <https://ember-energy.org/data/carbon-price-tracker/>
- [10] Vacanza et al. *holidays: generación de calendarios de festivos para Python*. 2026. <https://github.com/vacanza/holidays>
- [11] Red Eléctrica de España. *Sistema de Información del Operador del Sistema (ESIOS)*. API: <https://api.esios.ree.es>. 2026. <https://www.esios.ree.es>
- [12] Agencia Estatal de Meteorología. *AEMET OpenData*. 2026. <https://opendata.aemet.es/centra>
- [13] Chen, Tianqi y Carlos Guestrin. “XGBoost: A Scalable Tree Boosting System”. En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, págs. 785-794. doi: 10.1145/2939672.2939785
- [14] Ke, Guolin et al. “LightGBM: A Highly Efficient Gradient Boosting Decision Tree”. En: *Advances in Neural Information Processing Systems*. Vol. 30. 2017.
- [15] Hochreiter, Sepp y Jürgen Schmidhuber. “Long Short-Term Memory”. En: *Neural Computation* 9.8 (1997), págs. 1735-1780. doi: 10.1162/neco.1997.9.8.1735

- [16] Lim, Bryan et al. "Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting". En: *International Journal of Forecasting* 37.4 (2021), págs. 1748-1764. doi: 10.1016/j.ijforecast.2021.03.012
- [17] Lundberg, Scott M. y Su-In Lee. "A Unified Approach to Interpreting Model Predictions". En: *Advances in Neural Information Processing Systems*. Vol. 30. 2017.
- [18] NEMO Committee. *EUPHEMIA Public Description: Single Price Coupling Algorithm*. Comité de operadores nominados del mercado eléctrico europeo. 2020. <https://www.nemo-committee.eu/euphemia>

Listado de acrónimos y abreviaturas

ACF Función de autocorrelación (*Autocorrelation Function*).

AEMET Agencia Estatal de Meteorología.

API Application Programming Interface.

BOE Boletín Oficial del Estado.

CO₂ Dióxido de carbono.

DM Contraste de Diebold-Mariano.

ENTSO-E European Network of Transmission System Operators for Electricity.

EPF Electricity Price Forecasting.

ESIOS Sistema de Información del Operador del Sistema.

ETS Emissions Trading System.

EUA EU Allowance, derecho de emisión de CO₂.

EUPHEMIA Pan-European Hybrid Electricity Market Integration Algorithm.

LightGBM Light Gradient Boosting Machine.

LSTM Long Short-Term Memory.

MAE Error absoluto medio (*Mean Absolute Error*).

MIBEL Mercado Ibérico de Electricidad.

MWh Megavatio-hora.

OMIE Operador del Mercado Ibérico de Energía, polo español.

PACF Función de autocorrelación parcial (*Partial Autocorrelation Function*).

PNIEC Plan Nacional Integrado de Energía y Clima.

PVPC Precio Voluntario para el Pequeño Consumidor.

REE Red Eléctrica de España.

RMSE Raíz del error cuadrático medio (*Root Mean Squared Error*).

SARIMAX Seasonal Auto-Regressive Integrated Moving Average with eXogenous regressors.

SDAC Single Day-Ahead Coupling.

SHAP SHapley Additive exPlanations.

sMAPE Symmetric Mean Absolute Percentage Error.

STL Seasonal-Trend decomposition using Loess.

TFM Trabajo de Fin de Máster.

TTF Title Transfer Facility, hub de gas neerlandés.

UTC Tiempo Universal Coordinado.

XGBoost eXtreme Gradient Boosting.